


智能无人系统





课件目录

- 第一章：认识无人驾驶系统
- 第二章：无人驾驶系统的定位方法以及传感器的应用
- 第三章：深度学习和无人驾驶视觉感知
- 第四章：迁移学习和强化学习在无人驾驶中的应用
- 第五章：无人驾驶的规划
- 第六章：车辆模型和高级控制
- 第七章：无人驾驶的平台介绍和系统安全
- 第八章：多智能体无人系统

第一章和第七章 无人驾驶平台和系统

自动驾驶的分级

SAE自动驾驶分级标准

- (1) **Level 0：无自动化。**
- (2) **Level 1：单一功能级自动化。**无法做到手和脚同时不操控。
- (3) **Level 2：部分自动化。**在某些预设环境下可以不操作汽车，即手脚同时离开控制。
- (4) **Level 3：有条件自动化。**特定条件部分任务。
- (4) **Level 4：高度自动化。**特定条件全部任务。
- (5) **Level 5：完全自动化。**全部条件全部任务。

传感器平台

主流的无人驾驶传感平台以**激光雷达和车载摄像头为主**，并呈现**多传感器融合**发展的趋势。了解各类传感器（激光雷达、毫米波雷达、摄像头、GPS/IMU、V2X通信传感系统）的**检测原理、优势、劣势以及功能**。

- (1) 激光雷达与毫米波雷达的检测原理、适用性；固态激光雷达；毫米波雷达的主频段。
- (2) 摄像头的优点和局限性；摄像头的各种类型和适用场景；
- (3) GPS和IMU各自的特点和局限性，两者相结合的优势；
- (4) **V2X通信传感系统的三大优势。（覆盖面更广、有效避免盲区、信息安全保护性更好）**

第一章和第七章 无人驾驶平台和系统

传感器小结

传感器	成本	优势	劣势	功能
激光雷达	8000 美元以上	扫描周围环境得到精确环境信息	成本高, 大雾、雨雪天气效果差, 无法图像识别	周边环境 3D 建模
毫米波雷达	300~500 美元	不受天气影响, 测量精度高, 距离范围广	无法识别道路指示牌, 无法识别行人	无法应用视觉识别要求较高功能
摄像头	35~50 美元	成本比较低, 通过算法可以实现各种功能	极端恶劣环境下会失效, 难以测距, 距离较近, 算法要求高	能实现大多数 ADAS 功能, 测距功能难以实现
V2X	150~200 美元	不受距离现实, V2X 成本较低, 深度融合智能系统	精度较低, 技术协议仍在讨论中, 普及难度大	利用通信协议, 感知实时路况, 道路信息和行人信息
红外传感器	600~2000 美元	夜视效果极佳	成本较高, 技术仍由国外垄断	夜视
超声波传感器	15~20 美元	成本低	探测距离较近, 应用局限大	侧方超车提醒、倒车提醒

各种传感器的比较

第一章和第七章 无人驾驶平台和系统

计算平台

了解四种计算解决方案

- 基于 GPU 的解决方案
- 基于 DSP 的解决方案
- 基于 FPGA 的解决方案
- 基于 ASIC 的解决方案

控制平台

控制平台主要包括了电子控制单元 ECU 与通信总线两大部分：

- ECU 主要实现控制算法
- **通信总线**主要实现ECU以及机械部件间的通信功能

通信网络协议

几种典型通信总线的数据传输方式、工作机制和适用场景：

- 局部互联协议 LIN（低速网络、适用于车内分布式电控系统、主从模式）
- 控制器局域网 CAN（中速网络、线型结构、节点并联、**仲裁机制**、能最大程度利用总线）
- 高速容错网络协议 FlexRay（高速安全可靠，时间触发和事件触发，不仅限于多媒体传输）

第一章和第七章 无人驾驶平台和系统

无人驾驶的安全性

常见攻击方式和解决方法

- 传感器的安全 (**使用多传感器融合技术互相纠正**)
- 操作系统的安全 (节点被劫持时, ROS系统可使用**容器技术和沙盒方式**)
- 控制系统的安全 (对 ECU 接收的信息进行**加密验证**)
- 车联网通信系统的安全性 (硬件、软件、安全证书)

第二章 无人驾驶系统的定位方法以及传感器的应用

定位技术

- 基于激光雷达点云数据的定位
- 基于GPS+ INS信息的定位
- 基于SLAM 技术的定位
- 基于高精度地图的定位技术

迭代最近点算法 (ICP)

- 算法原理：让第一组点云的每个点在第二组点云里找到一个最近的匹配，之后通过所有的匹配来计算均方误差，**匹配的过程实际上就是寻找最小均方误差的过程**。通过最小化误差来计算无人车与当前地图环境最匹配的位置坐标。
- ICP的求解分为两种方式：利用**线性代数**的求解（主要是**SVD**），以及利用**非线性优化**方式的求解。

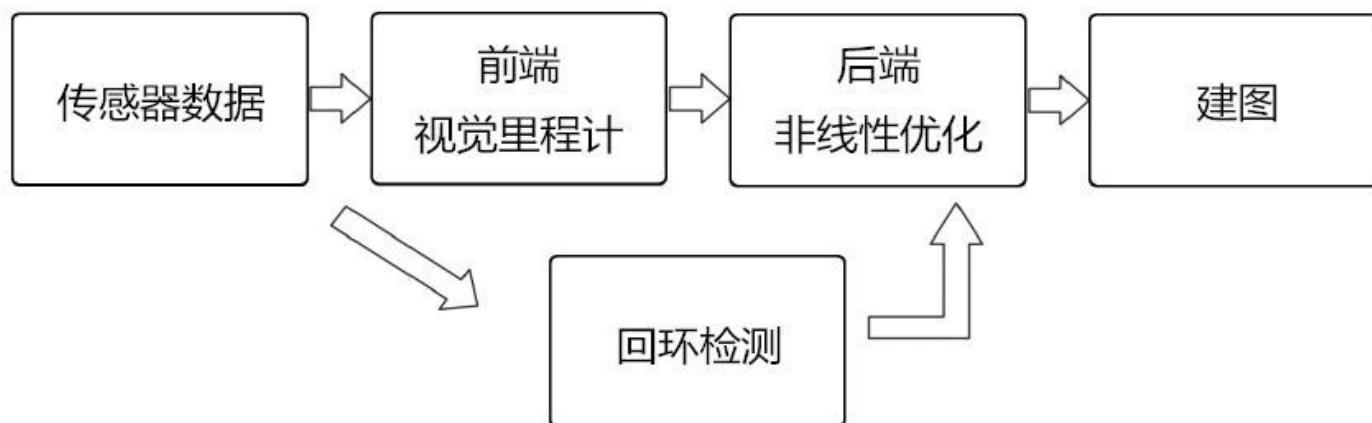
第二章 无人驾驶系统的定位方法以及传感器的应用

基于GPS+惯性组合导航的定位系统

- **惯性测量单元的检测原理、优缺点**（通过积分来确定导航信息，因此定位误差会累加。）
- **卫星导航系统 GNSS 系统**
 - (1) 三个主要部分（**空间段、控制段、用户段**）
 - (2) **三角定位法**: 三个卫星组成一个三角形，另外一个卫星提供对时校准
 - (3) 影响GPS定位准确度的因素: **大气层影响、卫星星历误差、卫星钟差、多路径效应。**
 - (4) 差分GPS定位的原理。（通过与**基准站**的比较，根据误差修正结果，提高定位精度。
位置差分、 距离差分）

第二章 无人驾驶系统的定位方法以及传感器的应用

基于SLAM的定位系统



SLAM框架

- SLAM定位系统完整架构由哪几部分组成、每一部分的作用。
- **回环检测**：判断机器人是否到达过先前的位置。步骤、意义（关系到估计的轨迹和地图在长时间下的正确性；由于回环检测提供了当前数据与所有历史数据的关联，可以进行**重定位**）
- 如何计算同一个向量在不同坐标系里的坐标？旋转加平移

$$a' = Ra + t.$$

第二章 无人驾驶系统的定位方法以及传感器的应用

视觉里程计——特征点法

特征点

- 图像当中具有代表性的部分（**可重复性、可区别性、高效性、本地性**）
- 特征点由关键点和描述子组成

关键点：特征点在图像中的位置、大小、方向等。

描述子：特征点周围的图像信息。

- **SIFT特征和FAST关键点的特点**
- **ORB特征**：关键点Oriented FAST和描述子BRIEF

FAST特征点计算仅仅是比较像素之间的亮度差异，所以它**不具有方向信息，也存在尺度问题**。所以ORB增添了尺度和旋转的描述。尺度不变性由**构建图像金字塔**，并在金字塔的每一层上检测角点来实现。而特征的旋转是由**灰度质心法**实现的。

特征匹配

- 特征点数目很大时，**暴力匹配法**的运算量很大，**快速近似最近邻FLANN算法**更适合匹配点数量极多的情况

第二章 无人驾驶系统的定位方法以及传感器的应用

视觉里程计——光流法

- 稀疏光流、稠密光流
- 灰度不变假设
- LK光流的结果依赖于图像梯度，有哪些缺点。解决方式：**多层光流**，引入图像金字塔来改善

回环检测

- 主流方法：基于外观的几何关系；核心问题：如何计算图像间的相似性
- 词袋模型：单词、字典
- 相似度计算：**TF-IDF (频率-逆文档频率)** 单词在图像中频率越高，则区分度越高；在字典中出现频率越低，则区分度越高。
- 基于词袋的回环检测完全依赖于外观，导致外观相似的图像容易被误认为回环，通常需进行**时间上的一致性检测和空间上的一致性检测**。

第二章 无人驾驶系统的定位方法以及传感器的应用

状态估计和传感器融合

卡尔曼滤波

- **基本思想：** 利用**前一时刻的估计值**和**现时刻的观测值**来更新对状态变量的估计，求出**现在时刻的估计值**。通过**卡尔曼增益**比较预测和观测的不确定性程度，来判断是更相信经验还是更相信传感器。（预测——实测——修正）
- 普通卡尔曼滤波的使用条件（**线性系统**、观测噪声和过程噪声服从**高斯分布**）

- **五个基本步骤：**

1. 状态预测： $\mathbf{x}'_k = \mathbf{A}\hat{\mathbf{x}}_{k-1} + \mathbf{B}u_k$
2. 计算预测误差： $\mathbf{P}'_k = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T$
3. 计算卡尔曼增益： $\mathbf{K}_k = \mathbf{P}'_k \mathbf{H}^T (\mathbf{H}\mathbf{P}'_k \mathbf{H}^T + \mathbf{R})^{-1}$
4. 计算最优估计值： $\hat{\mathbf{x}}_k = \mathbf{x}'_k + \mathbf{K}_k(\mathbf{z}_k - \mathbf{H}\mathbf{x}'_k)$
5. 计算最优估计值的误差： $\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}'_k$

思考：第四步已经算出最优估计值，为什么还要计算最优估计值的误差？

其中 \mathbf{A} 为状态转移矩阵， \mathbf{Q} 过程噪声的协方差矩阵， \mathbf{H} 为状态域到观测域的转换矩阵， \mathbf{R} 为观测噪声的协方差矩阵。

第二章 无人驾驶系统的定位方法以及传感器的应用

状态估计和传感器融合

扩展卡尔曼滤波

- 基本思想：扩展卡尔曼滤波的本质是使用线性变换来近似非线性变换。
- 五个基本步骤：

(1) 状态预测 $x_{k+1} = g(x_k, u)$

(2) 计算预测误差： $P_{k+1} = J_A P_k J_A^T + Q$

(3) 计算卡尔曼增益： $K_k = P_k J_H^T (J_H P_k J_H^T + R)^{-1}$

(4) 计算最优估计值： $x_k = x_k + K_k(z_k - h(x_k))$

(5) 计算最优估计值的误差： $P_k = (I - K_k J_H) P_k$

分别用雅可比矩阵 J_A 和 J_H 来代替线性系统中的状态转移矩阵和观测矩阵， Q 为过程噪声的协方差矩阵， R 为观测噪声的协方差矩阵。

第三章 深度学习和无人驾驶视觉感知

传统环境感知技术

基于激光雷达的路缘石检测

- 基本步骤
- 如何划分左右子集
- 如何拟合路缘石线

基于摄像机的车道线检测

- 基本步骤
- 形态学处理中的腐蚀和膨胀操作
- 如何拟合车道线

第三章 深度学习和无人驾驶视觉感知

机器学习概述

- 机器学习的基本分类
- 什么是经验风险最小化（损失函数、风险、经验风险）
- 欠拟合和过拟合
- 什么是梯度下降（向导数的反方向移动一小步来最小化目标函数的方法）
- 学习率的大小设置对学习过程的影响

神经网络基础

- 感知机的定义和模型
- 激活函数的作用、常用的激活函数
- 感知机与神经网络：单个感知机被证明**无法学习到异或（XOR）关系**，**神经网络优势**：在拥有足够多的隐藏层神经元节点的情况下，三层神经网络能够拟合任意函数。
- 前馈神经网络-输出方式：One-hot编码和SoftMax分类
- 前向传播和反向传播

第三章 深度学习和无人驾驶视觉感知

深度神经网络

- 正则化方法（数据集增强、提前终止、参数范数惩罚、丢弃技术等）
- 卷积神经网络的优势：“稀疏交互”、“权重共享”、“等变表示”
- 什么是卷积和池化、残差网络的作用
- 多通道卷积

YOLO算法

- 以YOLO为代表的单阶段目标检测算法与以RCNN为代表的深度学习目标检测算法最大的区别是什么？


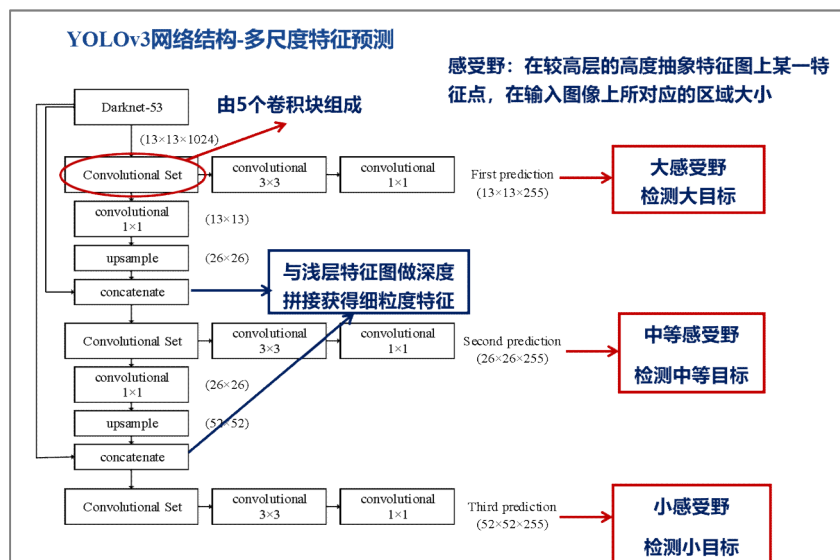
以RCNN系列为代表的深度学习目标检测算法采用**两阶段**的方法，首先生成候选区域，然后对这些候选区域进行分类和回归。YOLO**单阶段**目标检测算法中通过单个神经网络模型一次性完成目标检测和边界框回归。

第三章 深度学习和无人驾驶视觉感知

YOLO算法

- YOLOv3算法中，采用几种不同尺度的特征图进行目标检测？当输入图像分辨率为416*416时，请给出每种尺度特征图的大小以及特征图深度的计算方式。

YOLOv3算法中共包含3中不同尺度的特征图来进行目标检测，当输入图像分辨率为416*416时，三种尺度特征图的大小分别为13*13,26*26,52*52。其中特征图深度计算方式如下：深度=一个cell与n个锚框匹配*（中心偏移量+cell内是否含有物体+预测边界框的准确性（含有物体时）+物体类别概率）



第四章：迁移学习和强化学习在无人驾驶中的应用

迁移学习

迁移学习的必要性

矛盾	传统机器学习	迁移学习
大数据与少标注	增加人工标注，但是昂贵且耗时	数据的迁移标注
大数据与弱计算	只能依赖强大计算能力，但是受众少	模型迁移
普适化模型与个性化需求	通用模型无法满足个性化需求	模型自适应调整
特定应用	冷启动问题无法解决	数据迁移

迁移学习与传统机器学习的对比

比较项目	传统机器学习	迁移学习
数据分布	训练和测试数据服从相同的分布	训练和测试数据服从不同的分布
数据标注	需要足够的数据标注来训练模型	不需要足够的数据标注
模型	每个任务分别建模	模型可以在不同任务之间迁移

第四章：迁移学习和强化学习在无人驾驶中的应用

迁移学习方法

■ 常见的迁移学习方法分类

基于实例的迁移 (instance based TL)

- 通过权重重用源域和目标域的样例进行迁移

基于特征的迁移 (feature based TL)

- 将源域和目标域的特征变换到相同空间

基于模型的迁移 (parameter based TL)

- 利用源域和目标域的参数共享模型

基于关系的迁移 (relation based TL)

- 利用源域中的逻辑网络关系进行迁移

第四章：迁移学习和强化学习在无人驾驶中的应用

迁移学习应用场景

在开发深度学习模型时，并不一定需要从头开始训练模型。迁移学习可以方便将这些经典模型移植到新的应用场景中。

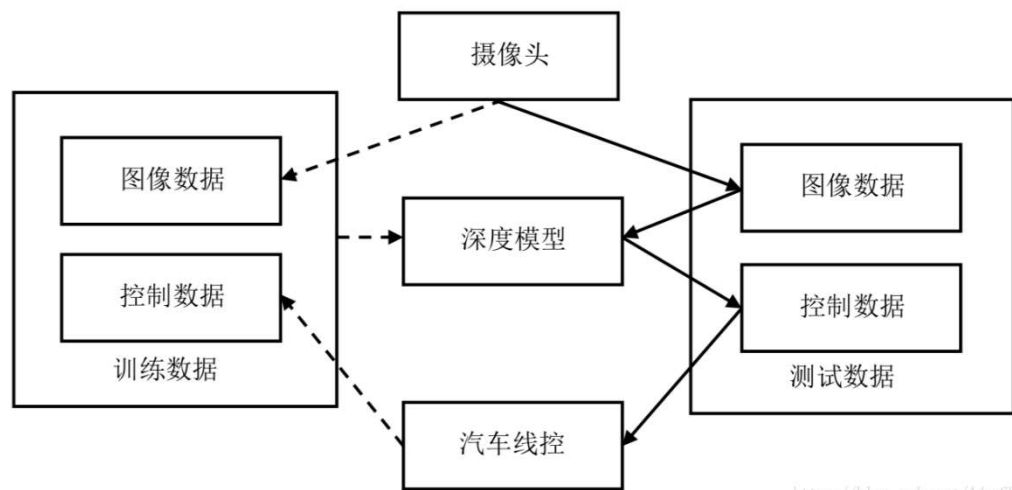
如何移植取决于两个因素：新应用数据量大小、新应用和原始模型的相似度。

数据集数量	应用相似度	模型训练方法
较大	较高	微调模型
较大	较低	微调或者重新训练
较小	较高	对全连接分类层进行修改训练
较小	较低	重新设计、重新训练模型

第四章：迁移学习和强化学习在无人驾驶中的应用

强化学习

1、端到端无人驾驶思路与模型



2、马尔可夫性和马尔可夫过程

3、非确定性策略和确定性策略

4、及时奖励和累计期望奖励


5、状态-值函数和状态-行为值函数之间的关系 $V_{\pi}(s) = \sum_{a \in A} \pi(a|s) q_{\pi}(s, a)$

第四章：迁移学习和强化学习在无人驾驶中的应用


强化学习

6、(1) DQN和Q-Learning算法的区别是什么？(2) DQN中的经验回放起到什么作用？

(3) DQN中的目标网络和评估网络有何区别及联系，分别承担什么作用？



Qtable—离散



Q值函数—连续

(1) DQN和Q-Learning算法的区别是什么？

Q-learning: **状态空间是离散的**, 算法维护一个**Q-table**, Q-table记录了不同状态下 $s(s \in S)$, 采取不同动作 $a(a \in A)$ 的所获得的Q值。

DQN: 是基于深度学习的Q-learning算法, **状态空间是连续的**, 不能用表格描述, **使用神经网络生成函数** $Q(s,a,w)$ 近似动作价值函数。


第四章：迁移学习和强化学习在无人驾驶中的应用

强化学习

6、(2) DQN中的经验回放起到什么作用？

- **基本思想**：将智能体的交互经验存储在一个经验池中，并在智能体进行更新时从经验池中随机采样一小批经验来进行训练。
- **作用**：智能体可以更好地利用过去的经验，提高学习效率，降低了采样成本。此外通过随机采样，经验回放可以减少训练数据之间的相关性，提高算法收敛速度。

(3) DQN中的目标网络和评估网络有何区别及联系，分别承担什么作用？



目标网络和评估网络 $Q(s, a, \theta)$ 结构一样，只是参数不同

$\theta' \neq \theta$ ，且参数更新频率也不同。在更新过程中，评估网络 $Q(s, a, \theta)$ 的权重 θ 会随着训练而不断更新，以逼近最优Q值函数。在训练学习过程中，某段时间内目标Q值一直保持不变，这一程度降低了当前Q值和目标Q值的相关性，提高了算法稳定性。

两个网络的作用不一样：评估网络用于估计Q值函数，收集经验，决定智能体的动作选择。目标网络是提供一个稳定的目标Q值，以减少训练中的估计偏差。

第四章：迁移学习和强化学习在无人驾驶中的应用

7、策略梯度：

通过最大似然和蒙特卡洛法计算梯度得到最终梯度公式：

$$\nabla_{\theta} J(\theta) = \frac{1}{N} \sum_{i=1}^T \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_i, t | s_i, t) \left(\sum_{t=0}^T r(s_i, t, a_i, t) \right) \right]$$


当前第n回玩游戏时，t时刻机器所看到的画面情况下做出a行为的概率

第n回完游戏时**总的奖励**

思考：如果换成t时刻的奖励会发生什么后果？

会导致只注重当前做的动作的回报，而不会注重整个游戏的过程中的奖励。容易陷入局部最优，无法更新到最优解。比如在射击游戏里，只有开火能得到奖励，那么就会导致机器只会开火。

第四章：迁移学习和强化学习在无人驾驶中的应用



8、深度确定性策略梯度算法 (DDPG) 使用演员-评论家 (Actor-Critic) 算法作为其基本框架，采用深度神经网络作为策略网络和动作值函数的近似。对于策略函数和价值函数均使用双重神经网络模型架构，请解释Critic目标网络和训练网络、Actor目标网络和训练网络分别的作用？

DDPG 共包含 4 个神经网络，用于对 Q 值函数和策略的近似表示。

- ❑ **Critic** 目标网络用于近似估计下一时刻的状态-动作的 Q 值函数，训练网络输出当前时刻状态-动作的 Q 值函数，用于对当前策略评价。
- ❑ **Actor** 目标网络用于提供下一个状态的策略，训练网络则是提供当前状态的策略，结合 Critic 训练网络的 Q 值函数可以得到 Actor 在参数更新时的策略梯度。

第五章：无人驾驶的规划

无人车路径规划和A*算法

深度优先搜索和广度优先搜索

- 两者有什么不同？

答：深度优先搜索沿着一条路径**不断往下搜索**直到不能再继续为止，然后再折返，开始搜索下一条路径。在深度优先搜索中，保存候补节点是栈，栈的性质就是**先进后出**。广度优先搜索根据离起点的距离，按照**从近到远**的顺序对各节点进行搜索，因此**能够找到最短路径**。在广度优先搜索中，有一个保存候补节点的队列，队列的性质就是**先进先出**。

Dijkstra算法

- 基本思想：**由近到远把所有点的最短路径算出来**
- 缺点：搜索最短路径时需要遍历整个离散空间，搜索的效率相对较低，计算开销也较大。

A*算法

- 基本思想：以**从起点到该点的距离加上该点到终点的估计距离之和作为该点的优先级**。

$$F^* = G + H^* \text{ (理解公式中各字母含义)}$$

第五章：无人驾驶的规划

无人车路径规划和A*算法

混合A*算法

比较A*和混合A*算法在节点字段定义、节点扩展方式、碰撞检测方式及距离定义方面的异同点

答：

- **节点字段定义：**经典A*包含的字段包括：F, G, H, 父节点。混合A*新增的字段包括：对应的位姿 $[x, y, \theta]$ ；节点是由何种 v, φ 扩展而来；由父节点到本节点的轨迹。
- **节点扩展方式：**经典A*扩展节点的方式就是找相邻节点。混合A*的扩展需要**考虑车辆动力学**。要求车辆在单位时间内，以恒定的速度和转角做匀速运动的，轨迹末端落入的三维网格就是要扩展的子节点。
- **碰撞检测方式：**经典A*算法中，判断是否碰撞只是检查对应网格是否被占据。混合A*需要将整条轨迹均匀采样，检测各采样时刻车辆位姿是否与障碍物碰撞。
- **距离定义：丰富了距离的含义。**混合A*从当前节点扩展到子节点的距离可以直接由 v *单位时间得到，此外，加入了对控制量 v, φ 频繁切换的惩罚。从当前节点到终点的估算距离综合考虑了车辆动力学和碰撞检测距离。

第五章：无人驾驶的规划

无人车路径规划

局部路径规划——TEB算法

算法基本原理

- 注意：每个目标函数只与elastic band中的某几个连续状态有关，而非整条band。
- 局部优化：“TEB”被表述为一个**多目标优化**问题，大多数目标都是局部的，只与一小部分参数相关，因为它们只依赖于几个连续的机器人状态。（哪些约束目标）
- 优化算法：使用开源框架 “**g2o**”：点(node) & 边(edge)。g2o: General Graph Optimization
通用图优化法
- 全局路径——加入约束——g2o优化——速度指令

第五章：无人驾驶的规划

无人车行为规划

有限状态机

- **算法基本原理**：只对**特定的外界输入**产生**数量有限的响应**
- **分类**：确定型自动机/非确定型自动机
- **存在问题**：当状态很多，有限状态机就有可能变得非常庞大，**可维护性差、可扩展性差、复用性差**

分层有限状态机

- **算法基本原理**：新增了**超级状态 (Super-state)**，将同一类型的一组状态合为一个集合。
- 斯坦福大学Junior：将顶层的驾驶行为分成了**13个超级状态**。在无人车正常行驶中，状态机**几乎处在普通驾驶模式**（即FORWARD_DRIVE和PARKING_NAVIGATE这两个状态）。
- **优点**：**分层结构**：将状态机分为不同的层次，每个层次可以包含多个子状态，子状态之间可以共享父状态的行为和事件，从而减少状态的数量和复杂度。
- **分层继承**：子状态可以继承父状态的属性和方法，同时也可以覆盖和扩展父状态的功能，从而提高状态机的可复用性和灵活性。
- **分层封装**：每个层次的状态机可以作为一个独立的模块，对外提供统一接口，提高可读性和可测试性。

第五章：无人驾驶的规划

无人车路径生成

使用三次样条插值算法

- **三次曲线和三次样条插值生成路径的区别：**三次样条插值拟合出来的曲线更加符合车辆运动学规律，汽车尽量走直线，只是在转变方向的地方形成一个符合汽车转弯特性的曲线路径。
- **三次样条插值算法的一些性质：**
 - 三次样条曲线在衔接点处是连续、光滑的。
 - 三次样条的一阶导数和二阶导数是连续可导的。
 - 自由边界三次样条(Nature Cubic Spline)的边界二阶导数也是连续的

第五章：无人驾驶的规划

动作规划


轨迹规划、速度规划

最优的动作序列

Jerk 即加速度的变化率，也即加加速度。过高的加加速度会引起乘坐者的不适，要解决的问题是研究如何优化Jerk。

Frenet坐标系

什么是Frenet坐标系，相对比笛卡尔坐标系的优势。



a) 笛卡尔坐标系

b) Frenet坐标系

笛卡尔坐标系和Frenet坐标系比较

第五章：无人驾驶的规划

横向轨迹优化

要在备选集合中选择最优轨迹（即图中**绿色轨迹**），需要设计一个较好的损失函数。对于不同的场景，损失函数也不相同。以**横向轨迹**为例，在较高速度的情况下，**损失函数**可设计为：

$$C_d = k_j J_t(d(t)) + k_t T + k_d d_1^2$$


该损失函数包含**三个惩罚项**：

$k_j J_t(d(t))$ ：惩罚Jerk较大的备选轨迹。

$k_t T$ ：制动应当迅速，时间短。

$k_d d_1^2$ ：目标状态不应偏离道路中心线太远。

k_j 、 k_t 和 k_d 是惩罚项的权重值，决定了损失函数更加偏向哪一方面的优化。



横向优化轨迹集

第五章：无人驾驶的规划

纵向轨迹优化

以车速保持为例，**损失函数**可设计为：

$$C_s = k_j J_t(s(t)) + k_t T + k_s (\dot{s}_1 - \dot{s}_c)^2$$


该损失函数包含**三个惩罚项**：

$k_j J_t(d(t))$ ：惩罚Jerk较大的备选轨迹。

$k_t T$ ：制动应当迅速，时间短。

$k_s (\dot{s}_1 - \dot{s}_c)^2$ ： \dot{s}_c 是**想要保持的纵向速度**，让目标配置中的纵向速度尽可能接近设定速度。

k_j 、 k_t 和 k_s 是惩罚项的权重值，决定了损失函数更加偏向哪一方面的优化。



纵向优化轨迹集合

第五章：无人驾驶的规划

碰撞避免

在完成所有备选轨迹的损失计算后进行一次轨迹检查，过滤不符合控制约束条件限制的、可能会碰撞障碍物的轨迹等，检查内容包括：

检查s方向上的速度是否超过设定的**最大限速**

检查s方向的加速度是否超过设定的**最大加速度**

检查轨迹的曲率是否超过**最大曲率**

检查轨迹是否会引起**碰撞**（事故）

第六章：车辆模型和高级控制

自行车模型

自行车模型的几个假设

运动学自行车模型

四个状态变量描述车辆状态（位置、偏航角、速度）

两个控制输入(a, δ_f)

根据运动学定理，定义了运动学自行车模型中**各个状态量的更新公式**

动力学自行车模型

当车辆以相对高的速度行驶时，**车轮的方向并不一定是车辆当前的速度方向。**

考虑各种各样的力的作用（**纵向力和侧向力**）

第六章：车辆模型和高级控制

PID控制

- 比例、积分、微分项各项的作用
- 增大**P系数**会增大无人车向着参考线方向运动的倾向；增大**D系数**会增大无人车转角快速变化的“阻力”，从而使得转向更加平缓
- **积分环节**消除稳态误差；**微分环节**使系统的响应速度变快

模型预测控制

- 模型预测控制三个因素：**预测模型、在线滚动优化、反馈校正**
- 各环节基本工作原理。

第六章：车辆模型和高级控制

轨迹追踪

基于几何追踪的方法——纯追踪

- 原理：

从自行车模型出发，以车后轴为切点、车辆纵向车身为切线，通过控制前轮转向角 δ ，使车辆沿着一条经过目标路径点的圆弧行驶。

(g_x, g_y) 是下一个要追踪的路径点，它位于已经规划好的全局路径中，现在需要控制车辆使得**车辆的后轴**经过该路径点， l_d 表示车辆当前位置（即后轴位置）到目标路径点 (g_x, g_y) 的距离， α 表示目前车身姿态和目标路径点的夹角，




图4.2 纯追踪几何学

第六章：车辆模型和高级控制

轨迹追踪

基于几何追踪的方法——纯追踪

- 原理：

纯追踪算法控制量 δ 的最终表达式：

$$\delta(t) = \tan^{-1}\left(\frac{2L \sin(\alpha(t))}{l_d}\right)$$

其中： L ：车辆的轴距（前后轮胎的距离）

$\alpha(t)$ ： t 时刻车身和目标路径点的夹角

l_d ：距离目标路径点的前视距离，一般将前视距离表示成**车辆纵向速度的线性函数**。

越大的前视距离意味着轨迹的追踪越平滑，但又会出现车辆在大转角处转向不足的问题。**越小的前视距离**会使得追踪更加精确会带来控制的震荡。




图4.2 纯追踪几何学