




## 第二章：

### 本章目录

### CONTENT

- 1、实现定位的原理
- 2、迭代最近点算法
- 3、正态分布变换
- 4、基于GPS+惯性组合导航的定位系统
- 5、基于SLAM的定位系统
- 6、视觉里程计和后端优化
- 7、状态估计和传感器融合**

## 2.7 状态估计和传感器融合



你正在使用汽车的导航系统。

## 2.7 状态估计和传感器融合

### 背景知识

- 状态估计：确定某一时刻目标的状态（速度，位置等）

- 高斯分布：
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right] \quad \mu: \text{均值} \quad \sigma^2: \text{方差}$$
$$P(x) = \frac{1}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right) \quad \Sigma: \text{协方差矩阵}$$

- 先验概率 $P(x)$ ：根据已有经验推断事件发生的概率
- 似然估计 $P(z|x)$ ：已知观测结果判断事件发生的概率
- 后验概率 $P(x|z)$ ：给定条件下的概率，即根据先验概率和似然估计推断出事件发生的概率

贝叶斯公式：

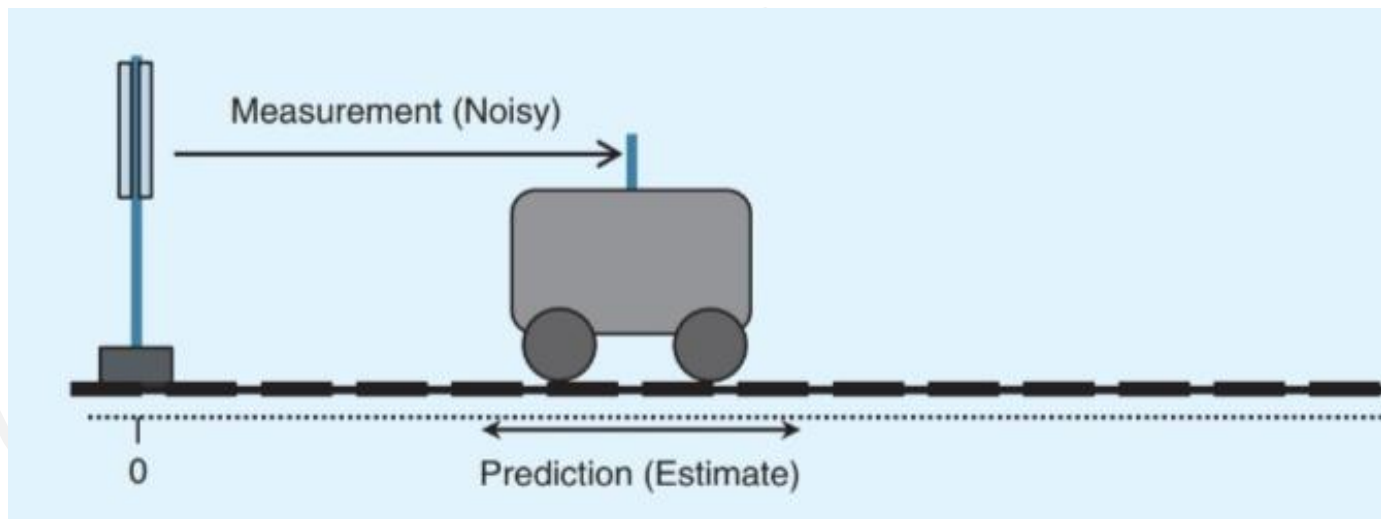
$$P(x|z) = \frac{P(x) \times P(z|x)}{P(z)}$$

## 2.7 状态估计和传感器融合

### 卡尔曼滤波简单示例

#### 问题描述

已知小车在道路上向右做匀速运动，在左侧安装了一个测量小车距离和速度传感器，传感器每1秒测一次小车的位置 $s$ 和速度 $v$ ，希望得到**第二秒**时的小车状态



用向量 $x_t$ 来表示当前小车的状态，该向量也是最终的输出结果，被称作**状态向量**。

$$x_1 = \begin{bmatrix} s_1 \\ v_1 \end{bmatrix}$$


$x_1$ 表示第一秒的状态

## 2.7 状态估计和传感器融合

### 卡尔曼滤波简单示例

预测：

使用历史信息对未来的位置进行推测。根据第1秒小车的位置和速度，推测第2秒时，小车所在的位置应该如下图所示。图中红色区域的范围变大了，这是因为预测时加入了速度估计的**噪声**，是一个放大不确定性的过程。



得到预测状态 $x_{pre}$ ：

$$x_{pre} = \begin{bmatrix} s_1 + v_1 \\ v_1 \end{bmatrix}$$

## 2.7 状态估计和传感器融合


### 卡尔曼滤波简单示例

观测：

在第2秒时，传感器对小车的位置做了一次观测，我们认为小车在第2秒时观测值为 $z_2$ ，用向量表示第2秒时的观测结果为：

$$z_2 = \begin{bmatrix} s_2 \\ v_2 \end{bmatrix}$$

很显然，第二次观测的结果也是存在误差的，我们将预测的小车位置与实际观测到的小车位置放到一个图上，即可看到：



红色为预测位置，蓝色为观测到的位置

## 2.7 状态估计和传感器融合


### 卡尔曼滤波简单示例

更新：

观测和预测的结果都在真值旁边，为了尽可能接近真值，需要对两个结果进行**加权平均**：

$$x_2 = w_1 * x_{pre} + w_2 * z_2$$

两个权值的计算是根据预测结果和观测结果的**不确定性**来的，这个**不确定性**就是高斯分布中的**方差**的大小，方差越大，波形分布越广，不确定性越高，这样一来给的权值就会越低。最终得到：




**绿色**的区域就是通过融合预测和测量的数据，对小车位置的最佳估计

## 2.7 状态估计和传感器融合

### 卡尔曼滤波概述

- 卡尔曼滤波：是一种利用**线性系统**状态方程，通过系统输入输出观测数据，对系统状态进行最优估计的算法。
- 基本思想：采用信号与噪声的状态空间模型，利用**前一时**刻的估计值和**现时刻的观测值**来更新对状态变量的估计，求出**现在时刻的估计值**。
- 实质：预测——实测——修正





## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理



假设现在要进行火箭回收，在火箭降落到地表之前，需要知道火箭当前离地面的高度是多少，否则控制不当容易坠毁，这种情况下比较关心的**状态变量**就是**飞行器的离地高度**，然而飞行器的真实离地高度无法准确测量，所以需要对飞行器离地高度这个状态进行估计。

## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理

#### 1. 状态预测:

$$\text{Height}^{(k)} = 0.95 \times \text{Height}^{(k-1)}$$



过程模型:

$$x'_k = \alpha \hat{x}_{k-1}$$



加入噪声:

$$x'_k = \alpha \hat{x}_{k-1} + w_k$$

$x'_k$  : k时刻预测值

$\hat{x}_{k-1}$  : k-1时刻最优估计值

$\alpha$  : 常数系数 (本例=0.95)

$w_k$  : k时刻噪声

## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理

#### 2.计算预测误差:

$$P'_k = \alpha P_{k-1} \alpha^T$$

$P'_k$  : k时刻预测误差

$P_{k-1}$  : k-1时刻最优估计值的误差

$\alpha^T$  :  $\alpha$ 的转置

#### 3.观测模型:

$$z_k = x_k + v_k$$

$z_k$  : k时刻的测量值

$x_k$  : k时刻的真实值

$v_k$  : 测量噪声

测量值来自传感器（GPS、气压计），测量的结果带有误差，也称为**噪声**，由传感器精密度引起。通常来说，这种噪声满足**高斯分布**，它服从**均值为r、方差为 $\delta$** 的正态分布，均值**r**可通过测量或传感器厂商直接获得。

## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理

4. 计算卡尔曼增益:

$$K_k = P'_k / (P'_k + r)$$

$K_k$ : 卡尔曼增益

$P'_k$ : k时刻预测值的误差

$r$ : 测量噪声的均值

$\hat{x}_k$ : k时刻最优估计值

$x'_k$ : k时刻预测值

$z_k$ : k时刻测量值

5. 计算最优估计值:

$$\hat{x}_k = x'_k + K_k(z_k - x'_k)$$



$$\hat{x}_k = x'_k(1 - K_k) + K_k z_k$$



$$K_k = 0$$
$$\hat{x}_k = x'_k$$



$$K_k = 1$$
$$\hat{x}_k = z_k$$

## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理

6. 计算最优估计值的误差：

$$P_k = (1 - K_k)P'_k$$

$P_k$ ：k时刻最优估计值的误差

$P'_k$ ：k时刻预测误差

$K_k$ ：卡尔曼增益

第五步已经算出最优估计值，为什么还要计算最优估计值的误差？

$$P'_{k+1} = \alpha P_k \alpha^T$$

## 2.7 状态估计和传感器融合

### 卡尔曼滤波算法原理

总结:

预测

$$x'_k = \alpha \hat{x}_{k-1} + bu_k$$

$$P'_k = \alpha P_{k-1} \alpha^T$$

矩阵形式

$$\mathbf{x}'_k = \mathbf{A} \hat{\mathbf{x}}_{k-1} + \mathbf{B} u_k$$

$$\mathbf{P}'_k = \mathbf{A} \mathbf{P}_{k-1} \mathbf{A}^T$$

更新

$$K_k = P'_k / (P'_k + r)$$

$$\hat{x}_k = x'_k + K_k (z_k - x'_k)$$

$$P_k = (1 - K_k) P'_k$$

$$\mathbf{K}_k = \mathbf{P}'_k \mathbf{H}^T (\mathbf{H} \mathbf{P}'_k \mathbf{H}^T + R)^{-1}$$

$$\hat{\mathbf{x}}_k = \mathbf{x}'_k + \mathbf{K}_k (z_k - \mathbf{H} \mathbf{x}'_k)$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}'_k$$

## 2.7 状态估计和传感器融合

### 无人车传感器



## 2.7 状态估计和传感器融合


### 无人车传感器






## 2.7 状态估计和传感器融合

### 无人车传感器



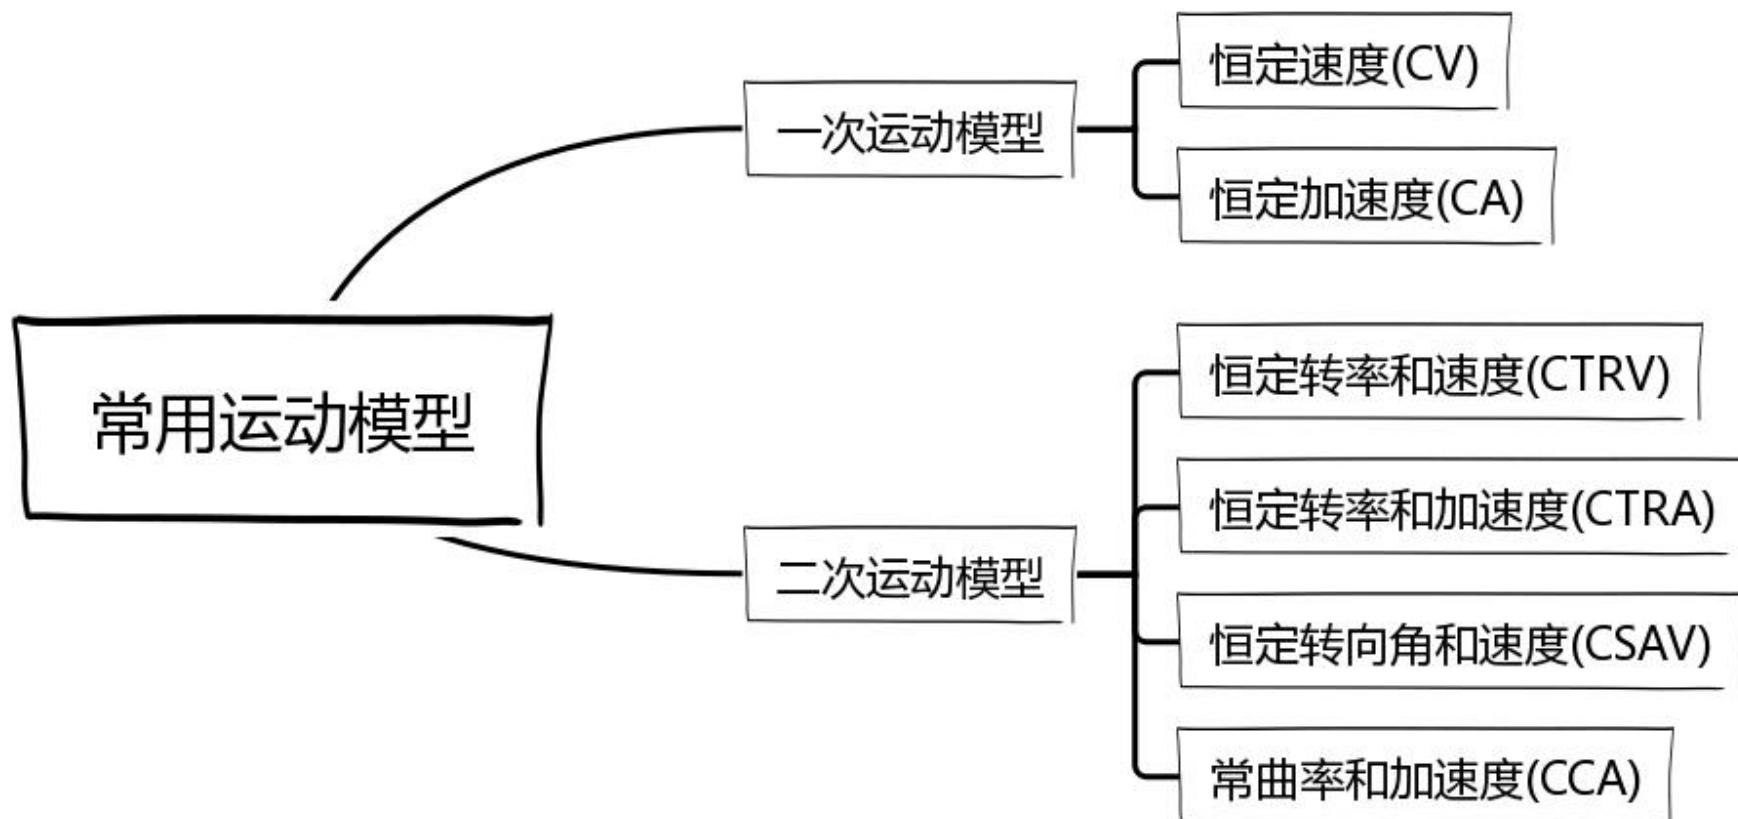
## 2.7 状态估计和传感器融合

### 无人车传感器



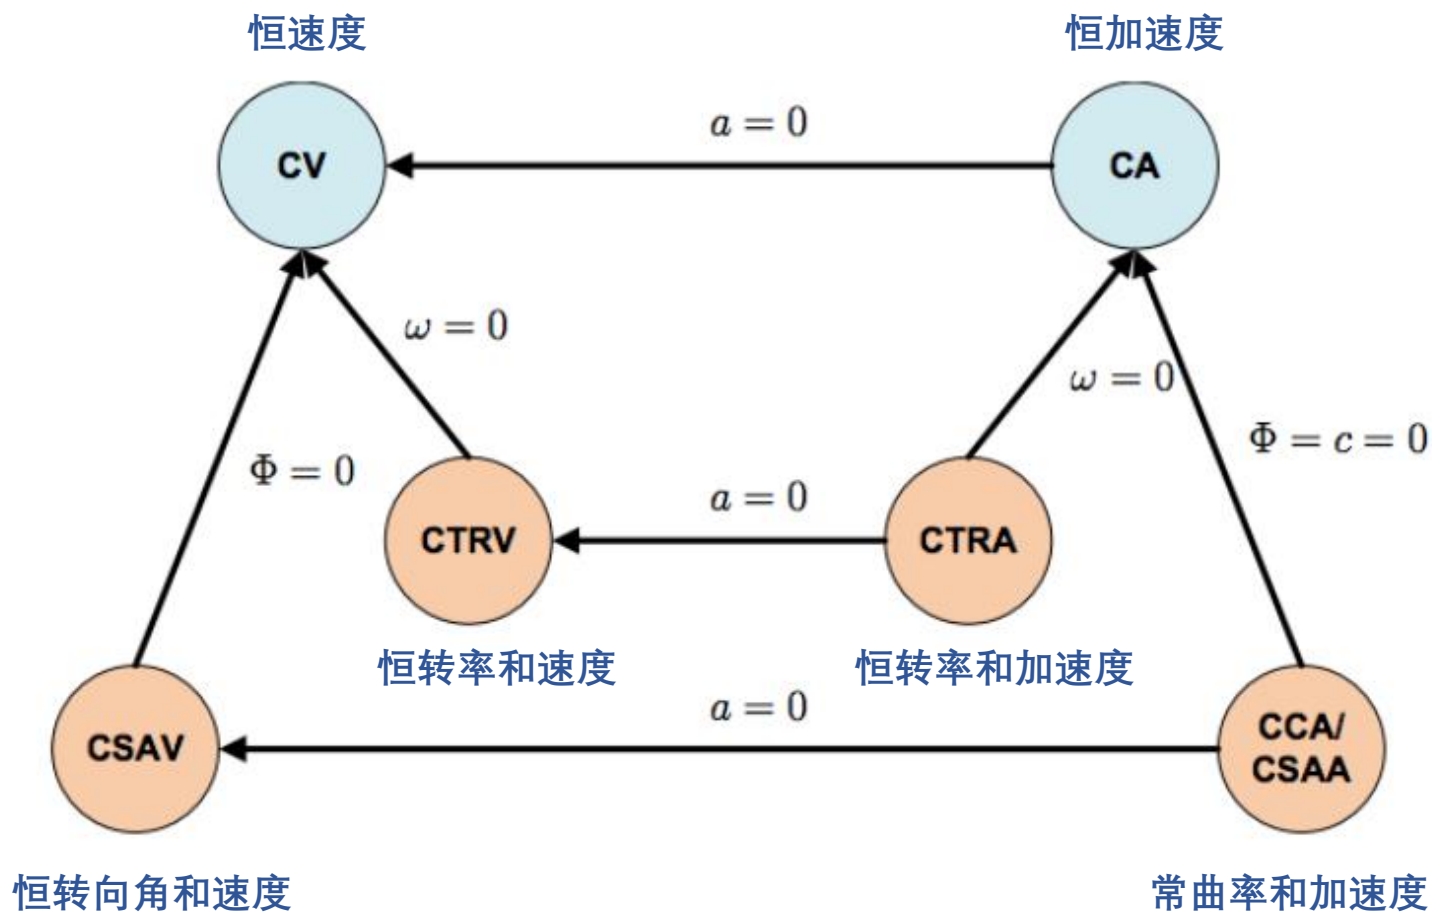
## 2.7 状态估计和传感器融合

常用运动模型：



## 2.7 状态估计和传感器融合

### 运动模型关系



运动模型关系图

## 2.7 状态估计和传感器融合

### 恒定速率 (CV) 模型:

① 状态空间:  $\vec{x}(t) = (x, y, v_x, v_y)^T$

$(x, y)$ 表示目标**位置**,  
 $(v_x, v_y)$ 表示目标在  
 $(x, y)$ 上的**速度**。

$$\text{状态转移函数: } \vec{x}(t + \Delta t) = \begin{pmatrix} x(t) + \Delta t v_x \\ y(t) + \Delta t v_y \\ v_x \\ v_y \end{pmatrix}$$

② 状态空间:  $x(k) = (x, y, \theta, v)^T$

$(x, y)$ 表示目标**位置**,  
 $\theta$ 表示目标**与x轴的夹角** (逆时针为正),  
取值范围  $[0, 2\pi)$ ,  $v$   
表示目标的**速度**。

$$\text{状态转移函数: } x(k + 1) = x(k) + \begin{pmatrix} v \cos \theta \Delta t \\ v \sin \theta \Delta t \\ 0 \\ 0 \end{pmatrix}$$

## 2.7 状态估计和传感器融合

### 卡尔曼滤波对行人状态估计

- 用向量表示行人状态:  $\vec{x}(t) = (P_x, P_y, v_x, v_y)^T$

- 生成过程模型, 假设行人**匀速**:  $x_{k+1} = Ax_k + q = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} P_x \\ P_y \\ v_x \\ v_y \end{pmatrix}_k + q$

过程噪声 $q$

- 行人状态估计中的**过程噪声**其实就是行人突然的加减速速度, 考虑行人的加速度因素, 模型变为:

$$x_{k+1} = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} P_x \\ P_y \\ v_x \\ v_y \end{pmatrix}_k + \begin{pmatrix} \frac{1}{2}a_x\Delta t^2 \\ \frac{1}{2}a_y\Delta t^2 \\ a_x\Delta t \\ a_y\Delta t \end{pmatrix}_k$$

$$P'_k = AP_{k-1}A^T \quad \longrightarrow \quad P'_k = AP_{k-1}A^T + \mathbf{Q}$$

## 2.7 状态估计和传感器融合

### 卡尔曼滤波对行人状态估计

- $q \sim N(0, Q)$ ,  $Q$  是过程噪声  $q$  的协方差矩阵  $P'_k = AP_{k-1}A^T + Q$

$$Q = \begin{bmatrix} \sigma_{p_x}^2 & \sigma_{p_x p_y} & \sigma_{p_x v_x} & \sigma_{p_x v_y} \\ \sigma_{p_y p_x} & \sigma_{p_y}^2 & \sigma_{p_y v_x} & \sigma_{p_y v_y} \\ \sigma_{v_x p_x} & \sigma_{v_x p_y} & \sigma_{v_x}^2 & \sigma_{v_x v_y} \\ \sigma_{v_y p_x} & \sigma_{v_y p_y} & \sigma_{v_y v_x} & \sigma_{v_y}^2 \end{bmatrix}$$

- 矩阵对角位置为状态向量中每个变量自身的方差，比如  $\sigma_{p_x}^2$  为 x 方向位置在预测中表示不确定性的方差
- Q 如何确定？  
——通过**加速度的方差**来推导，由被追踪物体的**极限性质**来确定，如高速场景下汽车的最大加速度是  $8.8\text{m/s}^2$ ，行人加速度  $0.5\text{m/s}^2$ 。

## 2.7 状态估计和传感器融合

### 卡尔曼滤波对行人状态估计

• 拆解过程噪声  $\mathbf{q} = \begin{bmatrix} \frac{a_x \Delta t^2}{2} \\ \frac{a_y \Delta t^2}{2} \\ a_x \Delta t \\ a_y \Delta t \end{bmatrix} = \begin{bmatrix} \frac{\Delta t^2}{2} & 0 \\ 0 & \frac{\Delta t^2}{2} \\ \Delta t & 0 \\ 0 & \Delta t \end{bmatrix} \begin{bmatrix} a_x \\ a_y \end{bmatrix}$  定义  $\mathbf{G} = \begin{bmatrix} \frac{\Delta t^2}{2} & 0 \\ 0 & \frac{\Delta t^2}{2} \\ \Delta t & 0 \\ 0 & \Delta t \end{bmatrix}$   $\alpha = \begin{bmatrix} a_x \\ a_y \end{bmatrix}$

- 根据协方差公式得：

$$\mathbf{Q} = E[\mathbf{q}\mathbf{q}^T] = \mathbf{G} \cdot E[\mathbf{a}\mathbf{a}^T] \cdot \mathbf{G}^T = \mathbf{G} \begin{bmatrix} \sigma_{a_x}^2 & \sigma_{a_{xy}} \\ \sigma_{a_{xy}} & \sigma_{a_y}^2 \end{bmatrix} \mathbf{G}^T = \mathbf{G}\mathbf{Q}_v\mathbf{G}^T$$

- 一般情况下x和y方向的加速度没有相关性，所以记：

$$\mathbf{Q}_v = \begin{bmatrix} \sigma_{a_x}^2 & 0 \\ 0 & \sigma_{a_y}^2 \end{bmatrix}$$

- 将 $\mathbf{Q}_v$ 重新带回 $\mathbf{Q}$ ，得：

$$\mathbf{Q} = \mathbf{G}\mathbf{Q}_v\mathbf{G}^T = \begin{bmatrix} \frac{\Delta t^4}{4} \sigma_{a_x}^2 & 0 & \frac{\Delta t^3}{2} \sigma_{a_x}^2 & 0 \\ 0 & \frac{\Delta t^4}{4} \sigma_{a_y}^2 & 0 & \frac{\Delta t^3}{2} \sigma_{a_y}^2 \\ \frac{\Delta t^3}{2} \sigma_{a_x}^2 & 0 & \Delta t^2 \sigma_{a_x}^2 & 0 \\ 0 & \frac{\Delta t^3}{2} \sigma_{a_y}^2 & 0 & \Delta t^2 \sigma_{a_y}^2 \end{bmatrix}$$

$\sigma_{a_x}$   
 $\sigma_{a_y}$



## 2.7 状态估计和传感器融合

### 卡尔曼滤波对行人状态估计

假设传感器可测得行人位置

观测向量与状态向量维度不一致

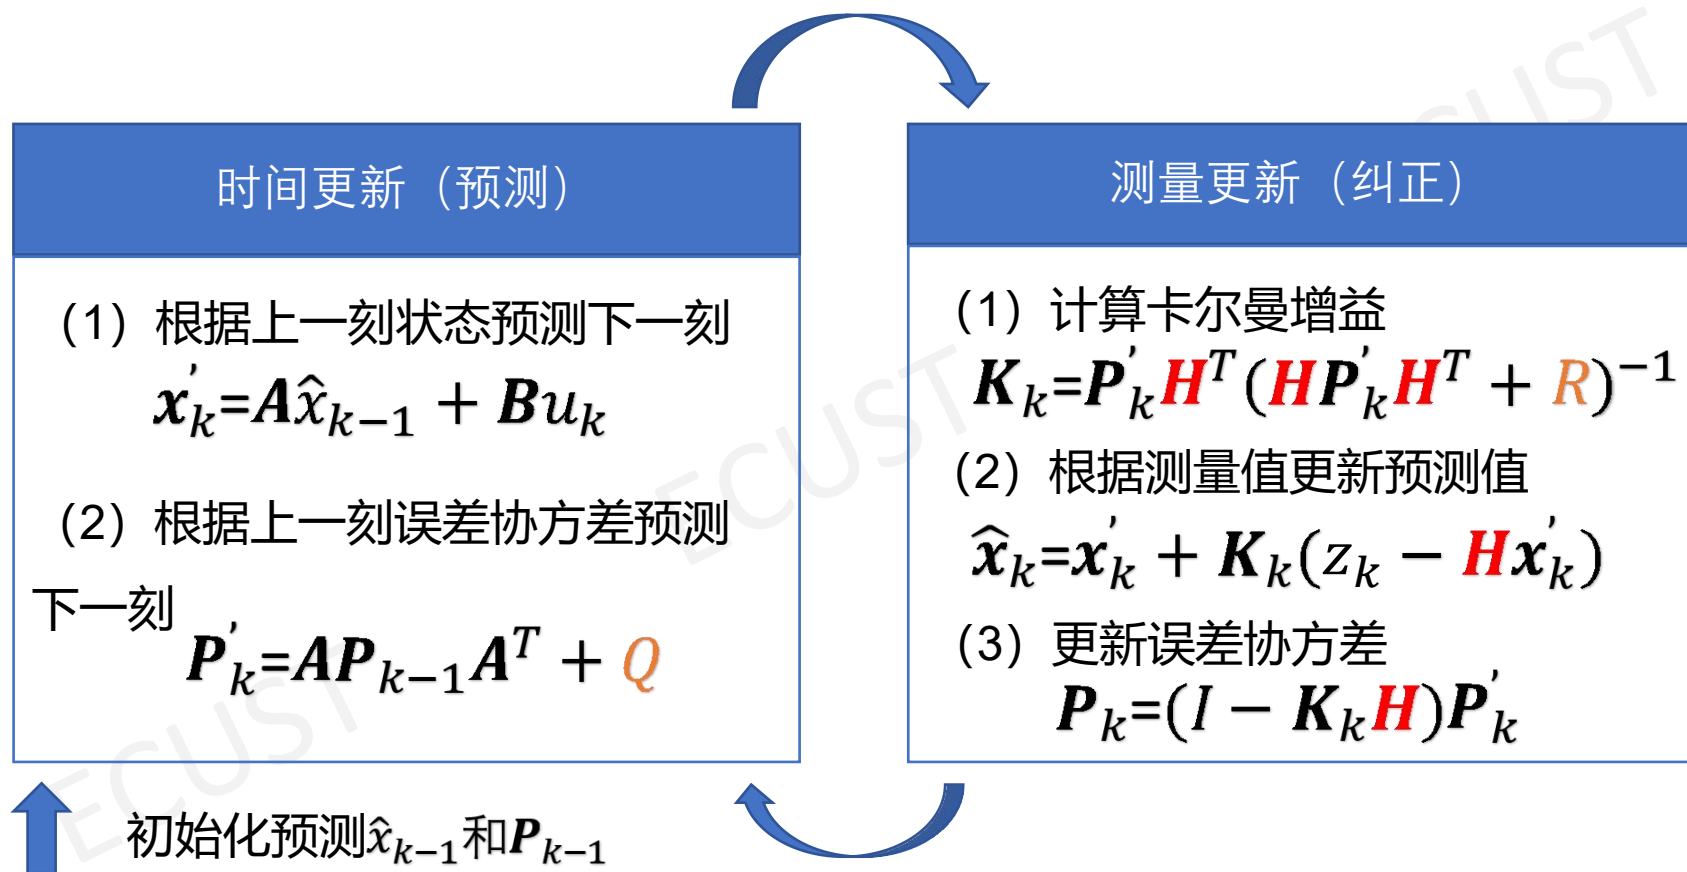
- 得观测向量  $z = \begin{bmatrix} p_x \\ p_y \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} p_x \\ p_y \\ v_x \\ v_y \end{bmatrix} = Hx$

- 观测矩阵  $H = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$  状态域到观测域转换矩阵

- 观测噪声的协方差矩阵  $R = \begin{bmatrix} \sigma_{p_x}^2 & \sigma_{p_x p_y} \\ \sigma_{p_x p_y} & \sigma_{p_y}^2 \end{bmatrix}$  由传感器性质决定

## 2.7 状态估计和传感器融合


卡尔曼滤波:



卡尔曼滤波流程图

## 2.7 状态估计和传感器融合

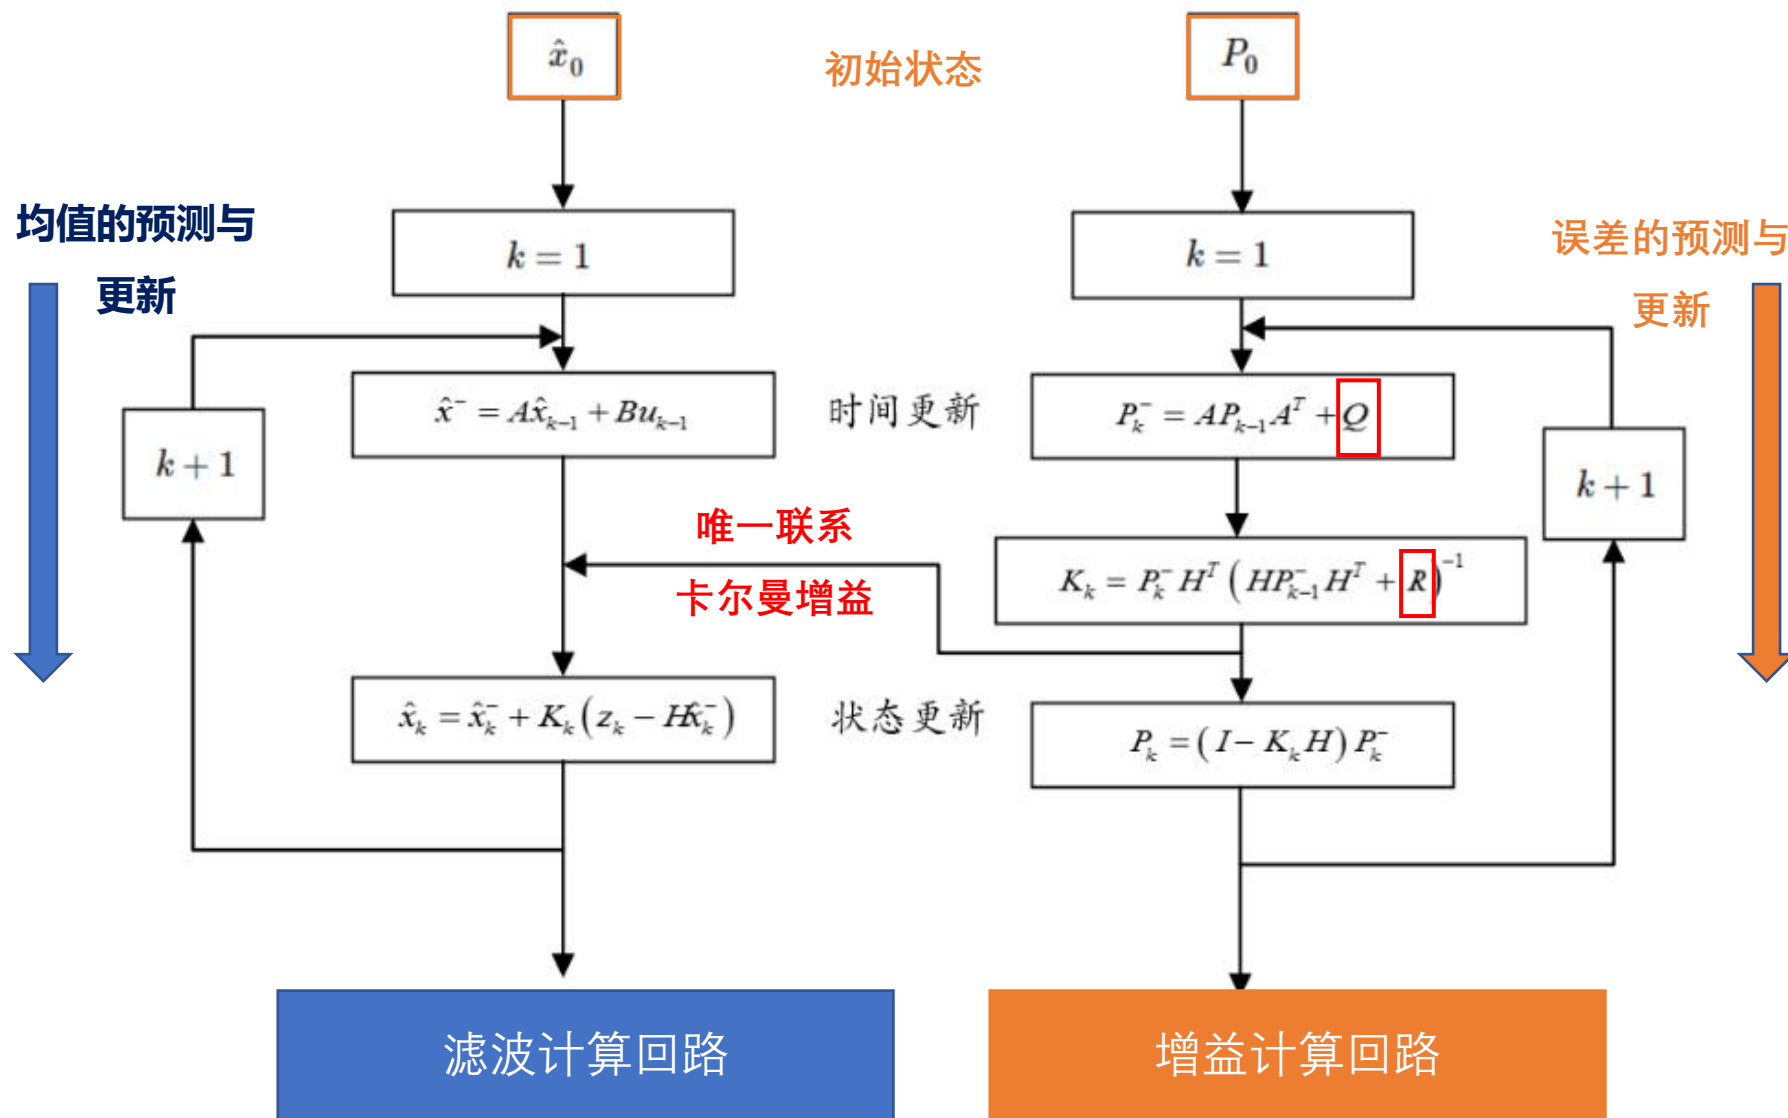
卡尔曼滤波：



- 观察这五个步骤，就是**求两个高斯分布的（预测和更新）的均值  $\hat{x}_k$ 、  
协方差  $P'_k$ 、 $P_k$**
- 通过卡尔曼增益比较预测和观测的不确定性程度，来判断是更相信经验还是更相信传感器。

## 2.7 状态估计和传感器融合

卡尔曼滤波:



## 2.7 状态估计和传感器融合

### 局限性


- 1.在组合信息大量冗余的情况下，计算量将以滤波器维数的三次方剧增，实时性不能满足；
- 2.传感器子系统的增加使故障随之增加，在某一系统出现故障而没有来得及被检测出时，故障会污染整个系统，使可靠性降低；
- 3.卡尔曼滤波可以对**线性系统**和**高斯噪声**进行精确的估计，但对与非线性系统和非高斯噪声的处理效果不佳。

## 2.7 状态估计和传感器融合

### 恒定角速度-速度 (CTRV) 模型:

状态空间:  $x(k) = (p_x, p_y, v, \psi, \omega)^T$

式中,  $(p_x, p_y)$ 表示目标**位置**,  $v$ 表示目标的**速度**,  $\psi$ 为**偏航角**, 是目标车辆在当前车辆坐标系下与x轴的夹角, 逆时针方向为正, 取值范围  $[0, 2\pi)$ ,  $\omega$ 是**偏航角速度**。



状态转移函数:  $x(k + 1) = x(k) + \begin{pmatrix} \frac{v}{\omega} \sin(\omega \Delta t + \psi_k) - \frac{v}{\omega} \sin(\psi_k) \\ -\frac{v}{\omega} \cos(\omega \Delta t + \psi_k) + \frac{v}{\omega} \cos(\psi_k) \\ 0 \\ \omega \Delta t \\ 0 \end{pmatrix}$

由于正余弦函数, 无法提出矩阵A  
不符合卡尔曼滤波的先决条件

## 2.7 状态估计和传感器融合

### 扩展卡尔曼滤波 (EKF) :

- 扩展卡尔曼滤波的本质是使用**线性变换来近似非线性变换**，线性变换中有一种强大的工具——泰勒展开。
- 多元函数泰勒展开： $T(x)=f(u) + (x-u)Df(u) + \frac{1}{2!}(x-u)^2D^2f(u) + \dots$
- 其中， $Df(u)$ 是在该处的**雅克比矩阵**，由于  $(x-u)$  本身数值很小，平方就更小了，所以高级数忽略不计，一般我们就考虑**一阶雅克比矩阵**进行线性化近似。

① 雅可比矩阵： $\mathbf{J} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \dots & \frac{\partial f}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$

$$x'_k = A\hat{x}_{k-1} + Bu_k$$

$$P'_k = \mathbf{A}P_{k-1}\mathbf{A}^T$$



$$x_k = g(x_{k-1}, u)$$

$$P_k = \mathbf{J}_A P_{k-1} \mathbf{J}_A^T + Q$$

## 2.7 状态估计和传感器融合

### 扩展卡尔曼滤波 (EKF)

$$x(k) = (p_x, p_y, v, \psi, \omega)^T, \quad x(k+1) = \begin{pmatrix} p_{x_k} + \frac{v}{\omega} \sin(\omega \Delta t + \psi_k) - \frac{v}{\omega} \sin(\psi_k) \\ p_{y_k} - \frac{v}{\omega} \cos(\omega \Delta t + \psi_k) + \frac{v}{\omega} \cos(\psi_k) \\ v \\ \psi_k + \omega \Delta t \\ \omega \end{pmatrix}$$

对各元素求偏导得 $J_A$ :

$$\begin{bmatrix} 1 & 0 & \frac{1}{w}(-\sin(\psi) + \sin(\psi + \omega \Delta t)) & \frac{v}{w}(-\cos(\psi) + \cos(\psi + \omega \Delta t)) & \frac{v \Delta t}{\omega} \cos(\omega \Delta t + \psi) - \frac{v}{\omega^2}(-\sin(\psi) + \sin(\omega \Delta t + \psi)) \\ 0 & 1 & \frac{v}{w}(-\sin(\psi) + \sin(\psi + \omega \Delta t)) & \frac{1}{w}(\cos(\psi) - \cos(\psi + \omega \Delta t)) & \frac{v \Delta t}{\omega} \sin(\omega \Delta t + \psi) - \frac{v}{\omega^2}(\cos(\psi) - \cos(\omega \Delta t + \psi)) \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

特殊情况下, 当 $\omega$ 等于0:

$$J_A = \begin{bmatrix} 1 & 0 & \cos(\psi) \Delta t & -\sin(\psi) v \Delta t & 0 \\ 0 & 1 & \sin(\psi) \Delta t & \cos(\psi) v \Delta t & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$



## 2.7 状态估计和传感器融合

### 扩展卡尔曼滤波 (EKF) :

② 过程噪声：直线加速度和偏航角加速度（满足均值为0，方差为 $\sigma_a^2$ 、 $\sigma_\omega^2$ ）

$$\text{noise} = \begin{pmatrix} \frac{1}{2}\Delta t^2 \mu_a \cos(\psi) \\ \frac{1}{2}\Delta t^2 \mu_a \sin(\psi) \\ \Delta t \mu_a \\ \frac{1}{2}\Delta t^2 \mu_\omega \\ \Delta t \mu_\omega \end{pmatrix} = \begin{pmatrix} \frac{1}{2}\Delta t^2 \cos(\psi) & 0 \\ \frac{1}{2}\Delta t^2 \sin(\psi) & 0 \\ \Delta t & 0 \\ 0 & \frac{1}{2}\Delta t^2 \\ 0 & \Delta t \end{pmatrix} \cdot \begin{pmatrix} \mu_a \\ \mu_\omega \end{pmatrix} = G \cdot \mu$$

- 过程噪声的协方差矩阵Q:

$$Q = E[\text{noise} \cdot \text{noise}^T] = E[G\mu\mu^T G^T] = G \cdot E[\mu\mu^T] \cdot G^T$$

- 一般情况下，线加速度和角加速度无相关性，所以得:

$$E[\mu\mu^T] = \begin{pmatrix} \sigma_a^2 & 0 \\ 0 & \sigma_\omega^2 \end{pmatrix}$$

## 2.7 状态估计和传感器融合

扩展卡尔曼滤波 (EKF) :

预测状态向量为  $x(k) = (p_x, p_y, v, \psi, \omega)^T$

③ 测量: **激光雷达**: 车辆位置  $(x, y)$

**毫米波雷达**:

- 极坐标距离  $\rho$
- 与x轴夹角  $\psi$
- 相对距离变化率  $\dot{\rho}$

• 对于激光雷达, 观测模型是线性的, 可得**观测矩阵**:  $H = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$

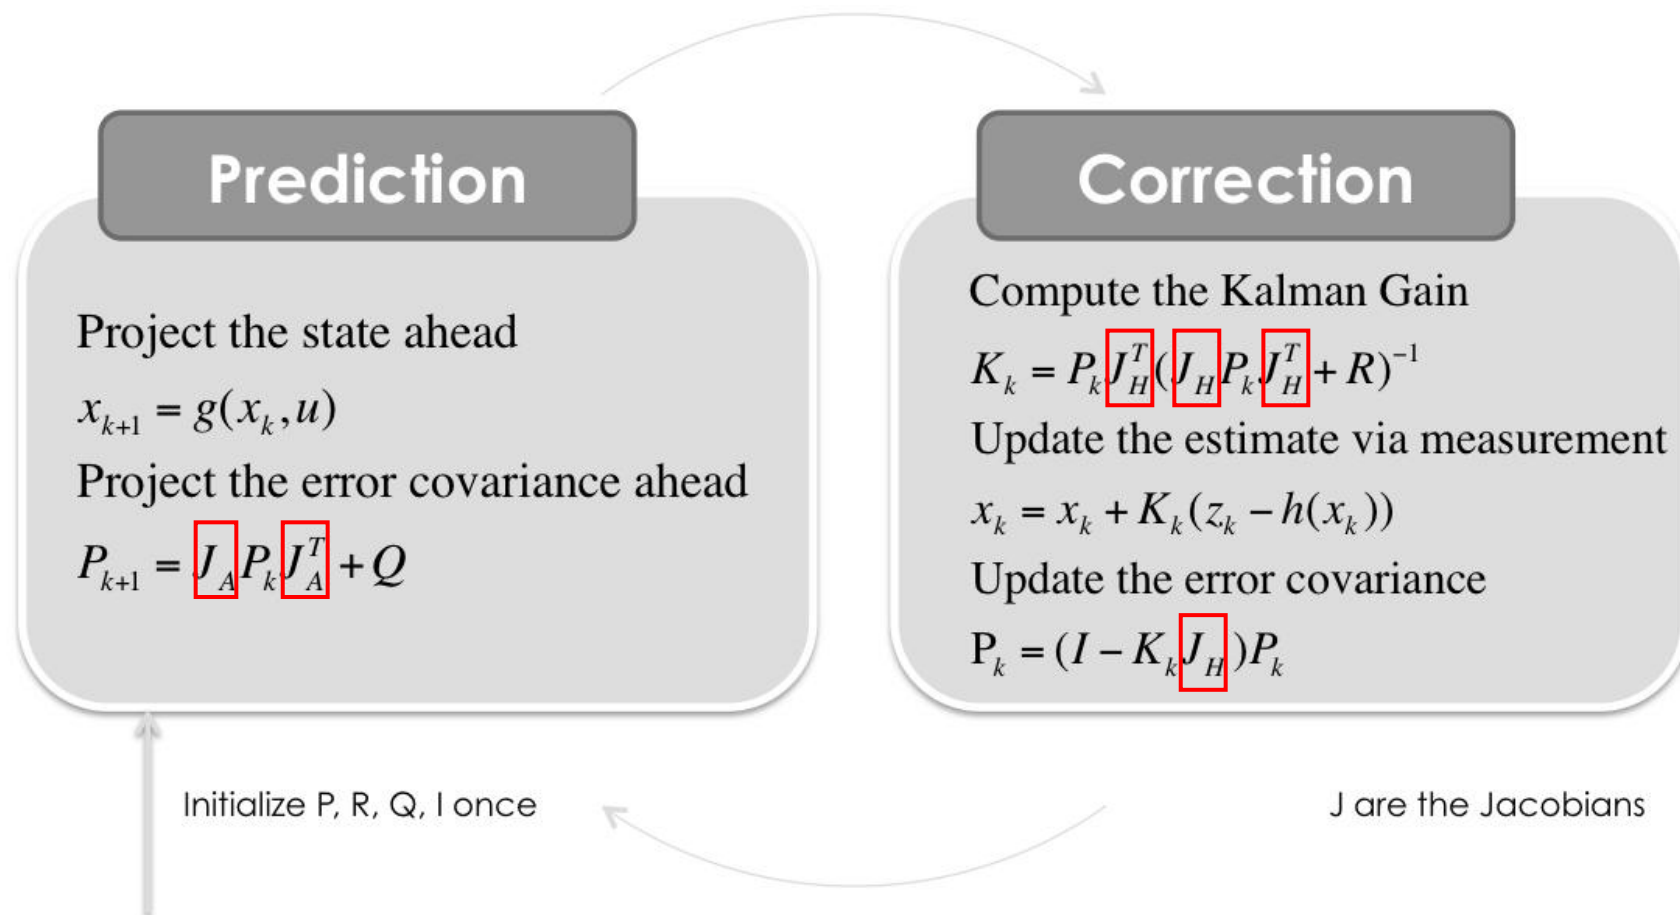
• 对于毫米波雷达, 预测映射到测量空间非线性的, 表达式为: 
$$\begin{pmatrix} \rho \\ \psi \\ \dot{\rho} \end{pmatrix} = \begin{pmatrix} \sqrt{x^2 + y^2} \\ \text{atan}(y, x) \\ \frac{vx + vy}{\sqrt{x^2 + y^2}} \end{pmatrix}$$

• 用 $h(x)$ 表示非线性映射, 求解 $h(x)$ 的**雅克比矩阵**:

$$J_H = \begin{bmatrix} \frac{x}{\sqrt{x^2 + y^2}} & \frac{y}{\sqrt{x^2 + y^2}} & 0 & 0 & 0 \\ -\frac{y}{x^2 + y^2} & \frac{x}{x^2 + y^2} & 0 & 0 & 0 \\ \frac{v}{\sqrt{x^2 + y^2}} - \frac{x(vx + vy)}{(x^2 + y^2)^{\frac{3}{2}}} & \frac{v}{\sqrt{x^2 + y^2}} - \frac{y(vx + vy)}{(x^2 + y^2)^{\frac{3}{2}}} & \frac{x + y}{\sqrt{x^2 + y^2}} & 0 & 0 \end{bmatrix}$$

## 2.7 状态估计和传感器融合

扩展卡尔曼滤波 (EKF) :




扩展卡尔曼滤波流程图

非线性的部分线性化，用雅可比矩阵代替状态转移矩阵和观测矩阵

## 2.7 状态估计和传感器融合

### 扩展卡尔曼滤波（EKF）：

简单例子：假设一架飞机以**恒定水平速度**飞行（高度不变），地面上有一个雷达可以发射电磁波测量飞机到雷达的**距离r**。



我们想知道某一时刻飞机的水平位置和垂直高度，以**水平位置、水平速度、垂直高度**作为状态变量：

$$\mathbf{x} = \begin{pmatrix} \text{distance} \\ \text{velocity} \\ \text{altitude} \end{pmatrix} = \begin{pmatrix} x \\ \dot{x} \\ y \end{pmatrix}$$

## 2.7 状态估计和传感器融合

### 扩展卡尔曼滤波 (EKF) :

- 状态转移矩阵为:

$$A = \begin{pmatrix} 1 & \Delta t & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

- 过程噪声的协方差矩阵为:

$$Q = \begin{pmatrix} \frac{1}{4}\Delta t^4\sigma_a^2 & \frac{1}{2}\Delta t^3\sigma_a^2 & 0 \\ \frac{1}{2}\Delta t^3\sigma_a^2 & \Delta t^2\sigma_a^2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

- 观测值与状态变量之间的关系为:

$$h(\hat{x}) = \sqrt{x^2 + y^2},$$

- 非线性映射 $h(\hat{x})$ 的雅可比矩阵:

$$J_H = \begin{bmatrix} \frac{x}{\sqrt{x^2 + y^2}} & 0 & \frac{y}{\sqrt{x^2 + y^2}} \end{bmatrix}$$

## 2.7 状态估计和传感器融合

EKF存在以下缺点：

1. 需要计算非线性模型的雅克比矩阵，计算大，易出错，难得到。
2. 忽略高阶项，估计精度大受影响。
3. 模型不确定性的鲁棒性很差。
4. 在系统达到平稳状态时，将丧失对突变状态的跟踪能力。
5. 如果系统的误差传播函数不能很好地用线性函数来逼近，可能会导致滤波器发散。
6. 因为偏导数高阶导数省略问题和雅克比矩阵计算难度的问题，让EKF的效果不是很好。

## 2.7 状态估计和传感器融合

### 无损卡尔曼滤波 (UKF) :

- UKF思想: 近似**概率分布**要比近似**非线性函数**更容易
- UKF核心: 无损变换
- UKF是对**非线性函数**的**概率分布**(均值 $\mu$ 和方差 $\sigma^2$ )进行**近似(sigma points)**, 用一系列确定的样本来逼近状态的后验概率分布。
- EKF 是通过**偏导数或连续差分**,经**雅克比矩阵**,对**非线性函数**  $f(x)$  本身进行**近似(线性化)**, 但是忽略了高阶导数。




图 4-8 无损变换

## 2.7 状态估计和传感器融合

### 无损卡尔曼滤波（UKF）算法流程：

预测：

- 产生sigma point点集
- 基于模型预测sigma point点集
- 计算新的均值和方差

更新：

- 预测测量值（UKF独有）
- 根据sigma point点集更新系统状态



## 2.7 状态估计和传感器融合

### 什么是传感器融合？

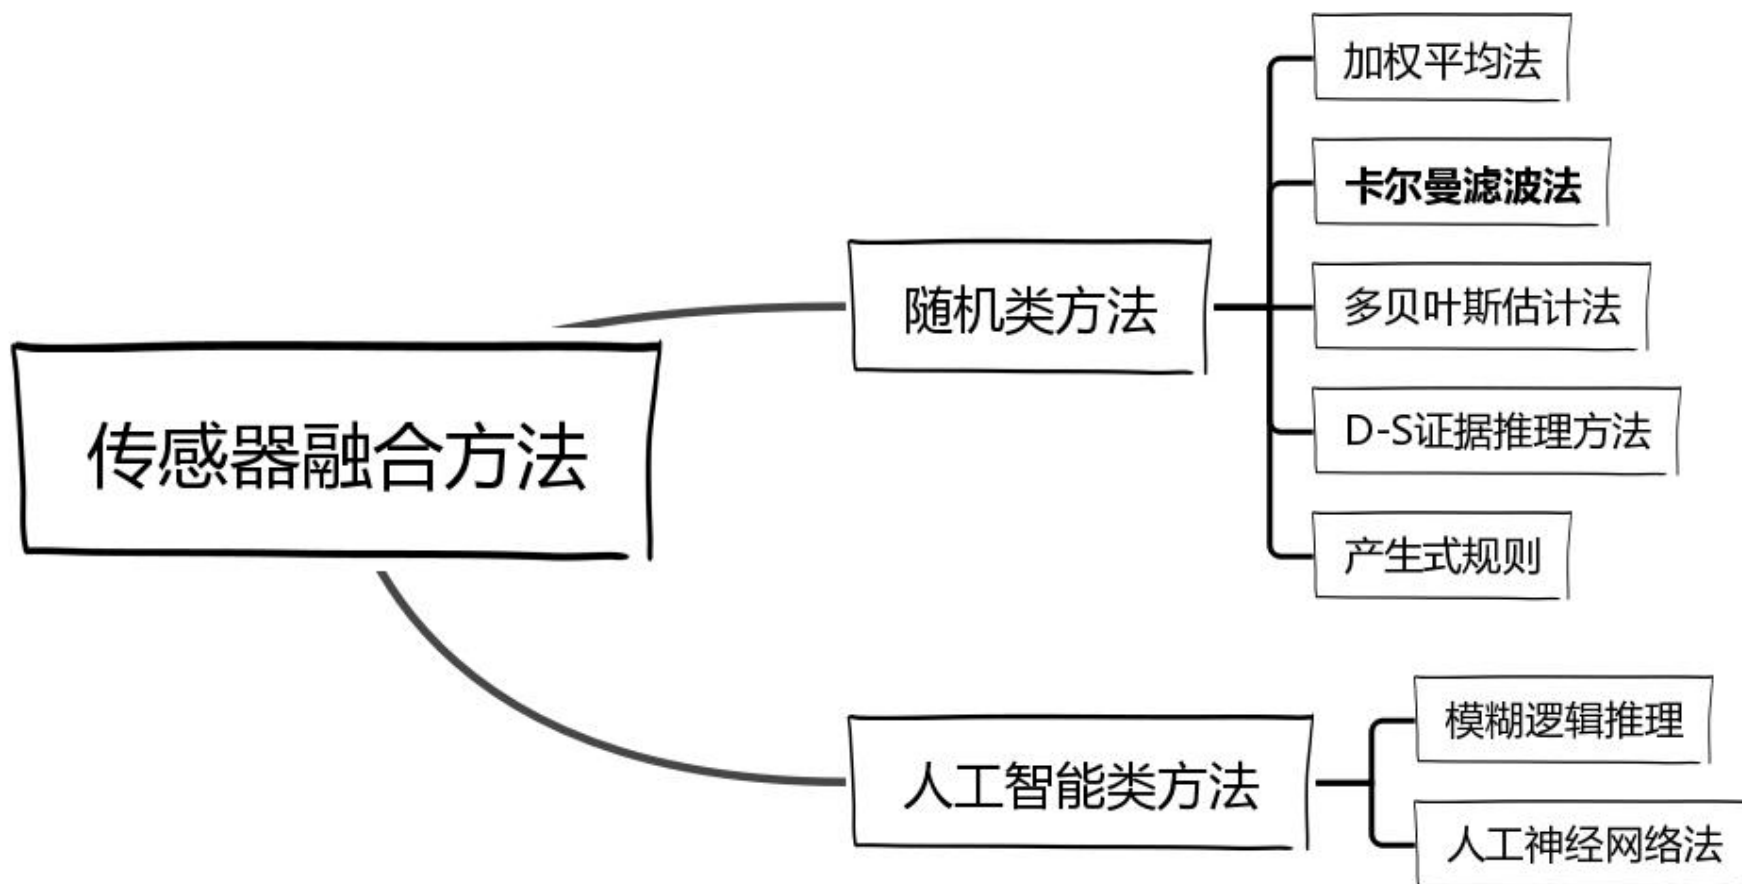
DannyData

多传感器融合

所谓多传感器融合就是 我先举个例子 什么叫多传感器融合？  
Multi-sensor fusion is, for example,

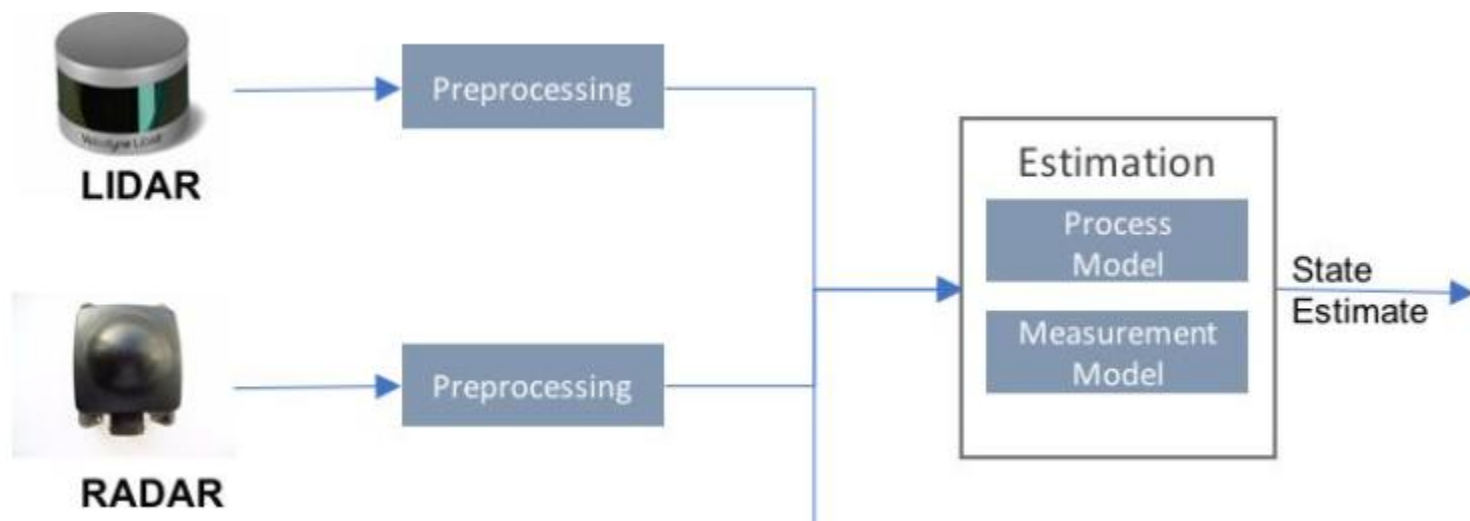
## 2.7 状态估计和传感器融合

### 传感器融合方法



## 2.7 状态估计和传感器融合

### 传感器融合

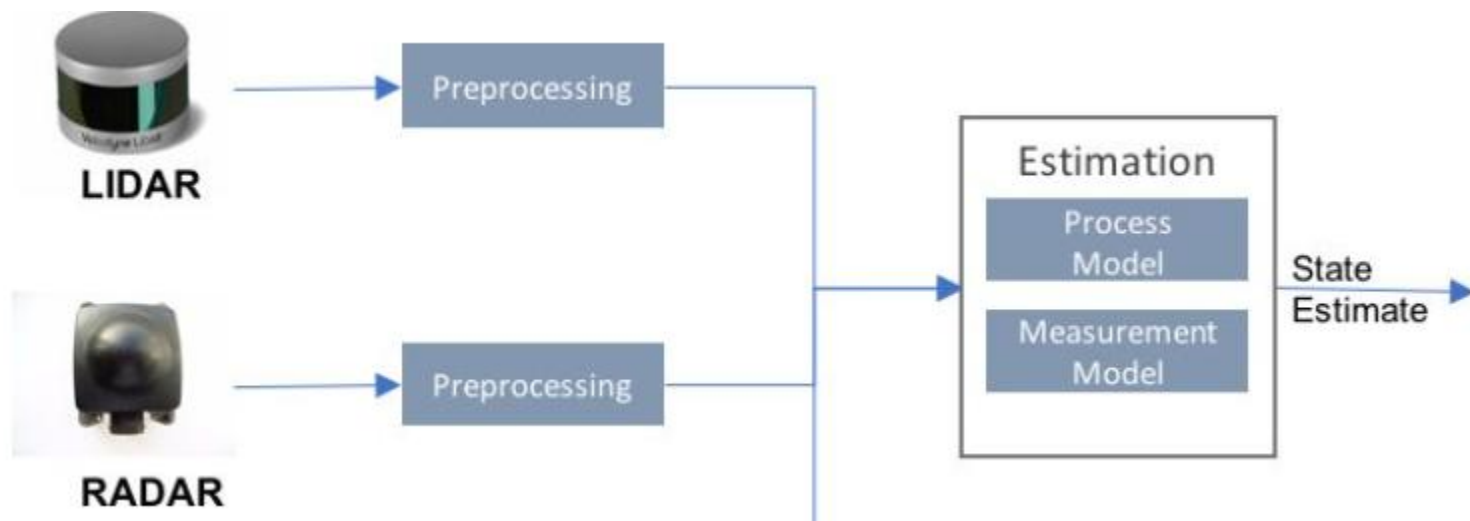


- 两个雷达测量数据**不在同一时间**得到：

根据测量数据的先后顺序，依次进行卡尔曼滤波迭代：假如 $k-1$ 时刻是激光雷达数据，则使用激光雷达的观测模型，计算得到 $k-1$ 时刻的最优估计值， $k$ 时刻观测数据由毫米波雷达测得，再变换观测模型，计算 $k$ 时刻最优估计值，每次卡尔曼滤波开始前先判断数据来源。

## 2.7 状态估计和传感器融合

### 传感器融合



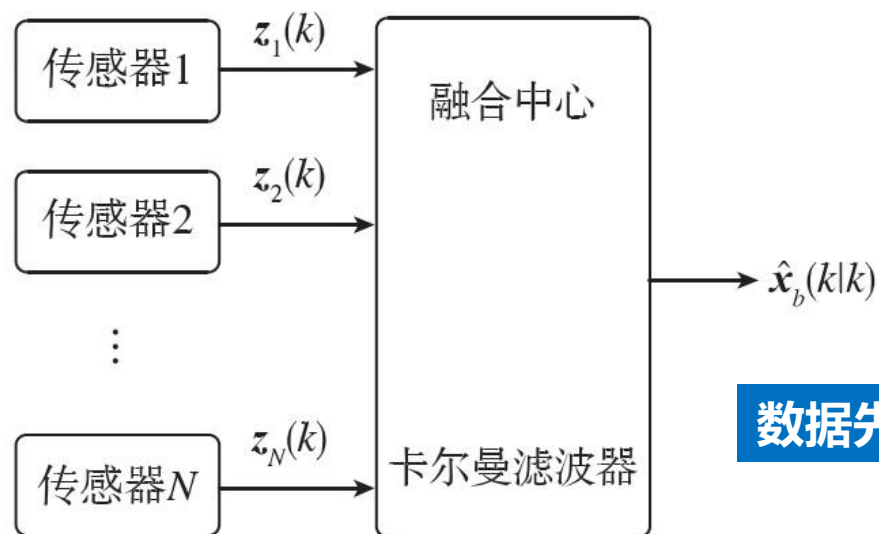
- 两个雷达测量数据**在同一时间**得到：

k时刻同时收到激光雷达和毫米波雷达数据，先预测k时刻的状态，使用任意一个传感器进行更新，得到第一次k时刻最优估计值，再使用另一个传感器信息进行更新，得到k时刻最终的最优估计值。（使用第一次得到的最优估计值作为第二次的预测值，相当于一次卡尔曼滤波做了一次**预测**，**两次更新**。）

## 2.7 状态估计和传感器融合


### 传感器融合

- 多个传感器同时获得数据



数据先融合，再滤波

(a) 并行滤波



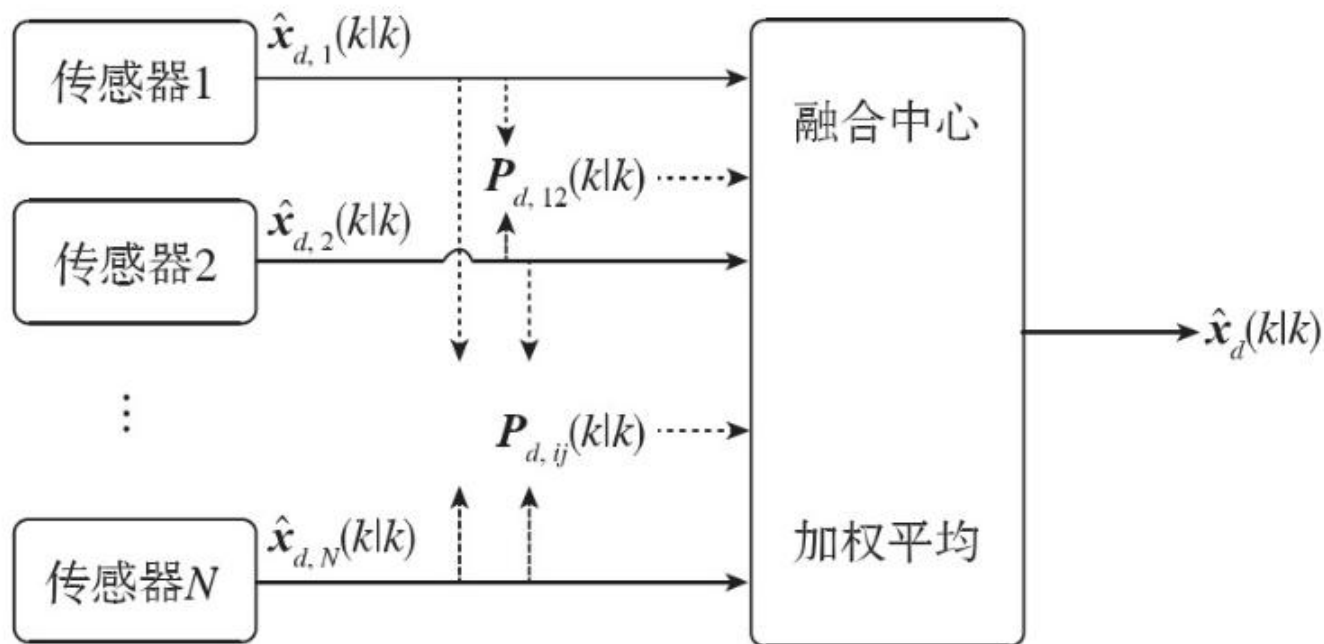
(b) 顺序滤波

一次预测，N次更新

## 2.7 状态估计和传感器融合

### 传感器融合

- 多个传感器同时获得数据



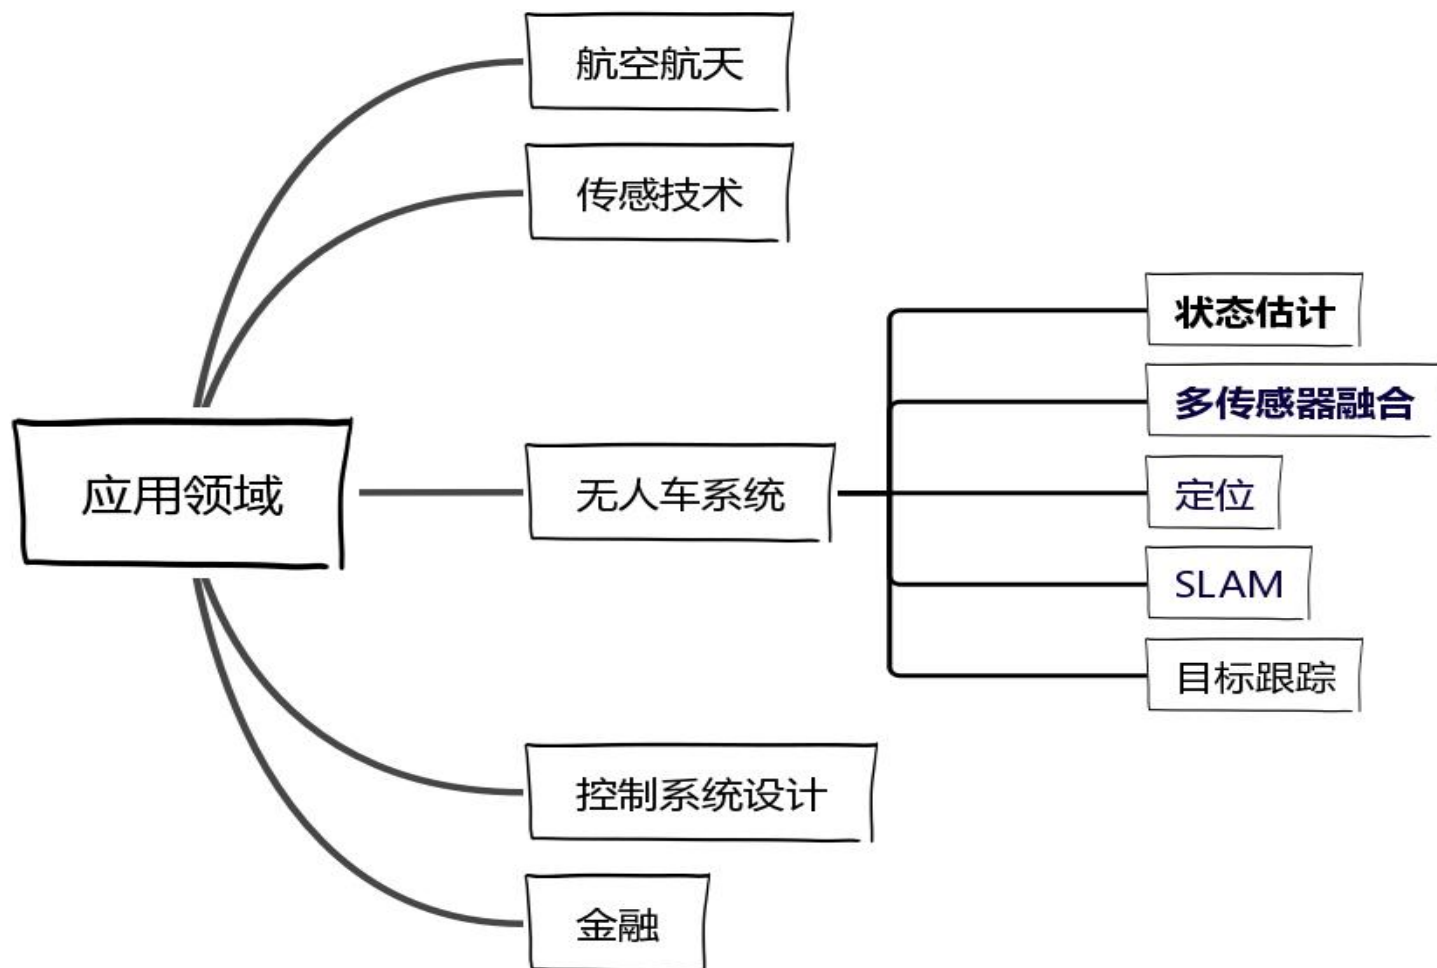
(c) 状态向量融合

分别滤波，再加权融合

- 具体方法：联邦滤波、数据压缩滤波、信息融合、并行滤波、一致性算法

## 2.7 状态估计和传感器融合

### 卡尔曼滤波应用



## 2.7 状态估计和传感器融合

### 基于卡尔曼滤波的单一目标追踪





## 2.7 状态估计和传感器融合

### 基于卡尔曼滤波的多目标追踪

红色球体 - 激光雷达探测的(x, y)

紫色线条 - 雷达探测到的沿着探测角度的速度大小

绿色球体 - 经过卡尔曼滤波预测后的车辆的位置(x, y)、速度和角度


Accuracy - RMSE:

0.060160

0.074419


0.642985

0.626054



## 2.7 状态估计和传感器融合

### 基于卡尔曼滤波的SORT目标跟踪实验



(a) 目标  
外观形变时的  
跟踪结果



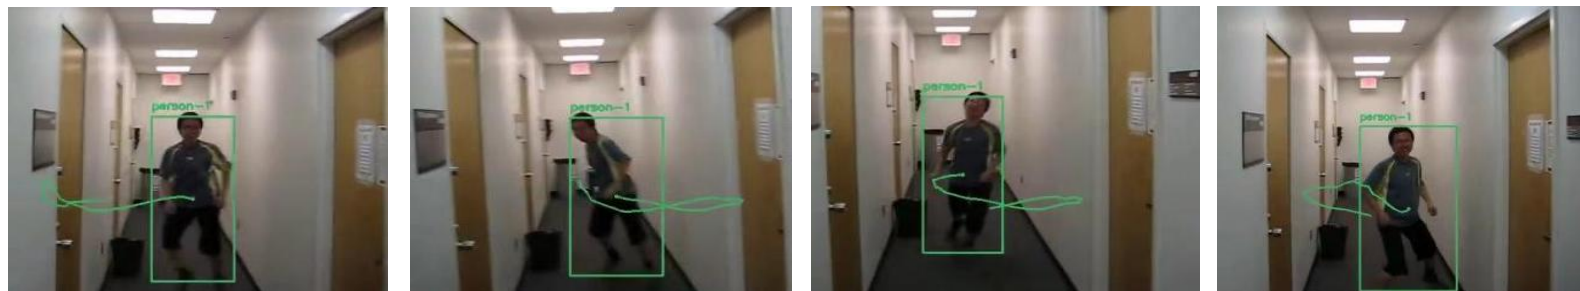
(b) 光照  
变化时的跟  
踪结果



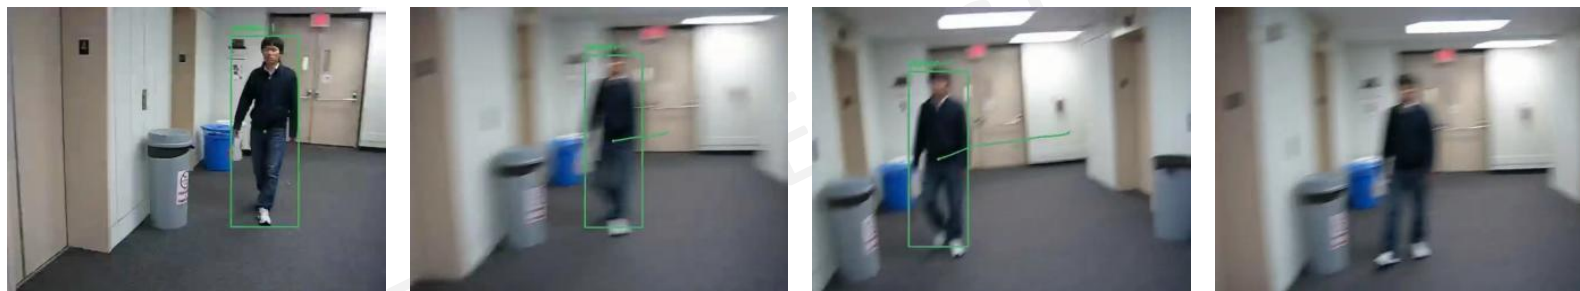
(c) 目标  
遮挡时的跟  
踪结果

## 2.7 状态估计和传感器融合

### 基于卡尔曼滤波的SORT目标跟踪实验



(d) 目标快速运动时的跟踪结果



(e) 镜头运动模糊时的跟踪结果



## 2.7 状态估计和传感器融合

### SORT算法在移动机器人上的实现：



小车**直行**跟踪效果



小车**转弯**跟踪效果



SORT算法在目标**外观形变**时的跟踪效果





## 2.7 状态估计和传感器融合

### SORT算法在移动机器人上的实现：




SORT算法在目标**运动模糊**时的跟踪效果




SORT算法在目标**快速运动**时的跟踪效果

## 2.7 状态估计和传感器融合

### 卡尔曼滤波在定位与SLAM中的应用




栅格地图



## 2.7 状态估计和传感器融合

### 通过深度相机进行避障





# 谢谢！

THANK YOU FOR LISTENING